Clasificación de Gravedad de Traumatismos de Cráneo Mediante Análisis de Imágenes por Tomografía Computada



Nicolás Del Piano

Dirigida por: Dr. Rafael Namías

Universidad Nacional de Rosario

Para la obtención del grado de

Licenciado en Ciencias de la Computación

Julio 2018

Agradecimientos

Resumen

El impacto del uso de imágenes digitales en la sociedad moderna es inmenso, a tal punto que el procesamiento de imágenes se ha convertido en un componente crítico para la evolución de la ciencia y tecnología en diversas áreas de acción, como la medicina. Este trabajo tiene como objetivo principal el análisis de imágenes tomográficas de cráneo en pacientes con traumatismo. El desarrollo consta de dos grandes etapas, primero la implementación de un método automático de extracción de características anatómicas de interés, y segundo el uso de métodos de aprendizaje automatizado para intentar predecir la severidad del trauma a partir de marcadores radiológicos y clínicos. Ambas etapas se evalúan frente a las anotaciones realizadas por expertos neurocirujanos.

Índice general

1. Introducción **1**

1.1. Problemática 1

1.2. Esquema general del trabajo 3

1.2.1. Ingreso del paciente 3

1.2.2. Base de datos 3

1.2.3. Preprocesamiento de la imagen TAC: registración y skull-stripping . . . 5

1.2.4. Extracción de características 5

1.2.5. Clasificación 6

2. Terminología médica **8**

2.1. Cerebro humano 8

2.2. Líquido Cefalorraquídeo 9

2.3. Sistema Ventricular 9

2.4. Imágenes Médicas 9

2.5. Tomografía Axial Computarizada (TAC) 10

2.6. Orientación 11

2.7. Huesos del cráneo y suturas 12

2.8. Traumatismo Craneoencefálico 13

2.9. Escala de Glasgow 13

2.10. Hipótesis de Monro-Kellie 15

2.11. Presión Intracraneal 16

2.12. Desviación de la Línea Media 16

3. Conceptos Generales **17**

3.1. Aprendizaje Automatizado . . . 17

3.1.1. Elementos del aprendizaje automatizado . . . 18

3.1.2. ¿Para qué estimar f? . . . 18

3.1.3. Aprendizaje Supervisado versus No Supervisado . . . 19

3.1.4. Aprendizaje Supervisado . . . 19

3.1.5. Sobreajuste . . . 20

3.1.6. Validación cruzada . . . 20

3.1.7. Sesgo inductivo . . . 21

3.1.8. Problemas de Clasificación versus Regresión . . . 22

3.2. Estimando f: Métodos de Aprendizaje . . . 22

3.2.1. Máquinas de Vectores de Soporte . . . 22

3.2.2. Árboles de Decisión . . . 29

3.2.3. Random Forest . . . 33

4. Extracción de características **36**

4.1. Materiales . . . 36

4.2. Extracción de la línea media ideal . . . 38

4.2.1. Método . . . 38

4.3. Extracción de la línea media deformada . . . 39

4.3.1. Generación del mapa de simetría . . . 40

4.3.2. El modelo paramétrico del algoritmo para la extracción de la dML . . . 40

4.3.3. Definición de la función dML como una función continua . . . 44

4.3.4. Obtención de la zona ventricular . . . 44

4.4. Cálculo de la desviación de la línea media . . . 45

4.5. Cálculo del área entre la iML y dML . . . 47

4.6. Resultados . . . 47

4.6.1. Sensibilidad y especificidad . . . 50

4.7. Discusión . . . 51

5. Experimentos **53**

5.1. Base de datos 53

5.1.1. Variables obtenidas en forma automática 53

5.2. Entrenamiento 54

5.3. Resultados 56

5.3.1. Predicción de la gravedad del trauma 56

5.3.2. Análisis y discusión del modelo propuesto 57

6. Conclusiones **61**

Bibliografía **63**

Capítulo 1

Introducción

1.1. Problemática

De acuerdo con la Organización Mundial de la Salud (OMS), el traumatismo craneoencefálico (TCE) se convertirá en una de las mayores causas de muerte para el año 2020. Con una estimada cifra anual de 10 millones de personas afectadas por TCE, la carga de mortalidad y morbilidad que esta condición impone en la sociedad, hacen del TCE un problema de salud pública de gran importancia [5].

El TCE se define como la alteración en la función neurológica u otra evidencia de patología cerebral a causa de un traumatismo que ocasione un daño físico en el encéfalo. Esta masa encefálica reside dentro del cráneo, comprendiendo el cerebro, el cerebelo y el tronco encefálico y está rodeada por líquido cefalorraquídeo (LCR o LCE) cuyo volumen en condiciones normales oscila entre 100 y 150 ml. Este traumatismo puede clasificarse en leve, moderado o severo: diversas características presentes en la imagen por Tomografía Axial Computada (TAC) pueden determinar a qué tipo pertenece.

Cuando se enfrenta un estudio médico, se deben identificar las variables clínicas de cada paciente que intervienen en el mismo. Generalmente, se consideran tres tipos de variables: de exposición, de resultado y de control. Las variables de exposición preceden el desenlace aportando pronósticos y factores de riesgo. Las variables de resultado, son las que miden el desenlace clínico en los pacientes estudiados. Por último, las variables de control abarcan aquellos datos que puedan influir en la determinación de la variable de resultado.

En el ambiente de la medicina, la información del dominio clínico es provista por las variables clínicas (datos de entrada, como el sexo o edad de la persona) y la imagen TAC del paciente. La inspección de una tomografía computada es indispensable en el diagnóstico y la evaluación de pacientes que sufren de traumas en la cabeza, y debe servir como herramienta para determinar resultados [4], debido a que describe las características físicas reales del paciente. Los rasgos que tienen gran importancia clínica incluyen analizar la relación entre



Figura 1.1: Hospital de Emergencias Dr. Clemente Álvarez, Rosario.

presión intracraneal (PIC) y el volumen de LCR, presencia de hematomas, desviación de la línea media (MLS) del cerebro, o la combinación de las particularidades previamente mencionadas. Los datos clínicos, que son extraídos de las bases de datos obtenidas del HECA e incluyen información del paciente y las anotaciones dadas por expertos, sirven de parámetros de entrada, junto con las características encontradas en el análisis de la imagen TAC, para entrenar un clasificador estadístico que determine la gravedad del trauma y sirva como soporte para el profesional médico al momento de concluír un diagnóstico.

En las imágenes por tomografía computada (TC), un número de imágenes 2-D son obtenidas al rotar un tubo de rayos-X alrededor del cuerpo del paciente. Luego, la imagen 3-D completa se reconstruye usando las proyecciones 2-D usando una transformación Radon [2]. Antes de comenzar a analizar una imagen TC, es necesario preprocesar la imagen obteniendo una región acotada, aplicando técnicas de segmentación. En particular, para obtener el área del cerebro que aporte información significativa, se utiliza una técnica de segmentación denominada *skull-stripping* que, a grandes rasgos, remueve la región no perteneciente a la parénquima[1]. Otras de las técnicas que se emplean es la registración, que permite alinear a un mismo espacio común múltiples imágenes, siendo muy útil en los casos donde las imágenes presentan distintas alineaciones.

Un cerebro sano exhibe una clara simetría a través del plano axial: el hemisferio derecho puede diferenciarse marcadamente del izquierdo. Esto hace importante considerar la información de la asimetría del cerebro, como la desviación de la línea media. Esta desviación, que se mide en milímetros, se obtiene trazando la línea media deformada (dML) y la línea media ideal (iML), obteniendo así la máxima distancia entre ambas. Esta característica, que se ha destacado en distintos trabajos [4, 6, 7], será estudiada para comprobar su relevancia en la gravedad del trauma.

[1]Tejido esencial de determinados órganos, en este caso, tejido cerebral.

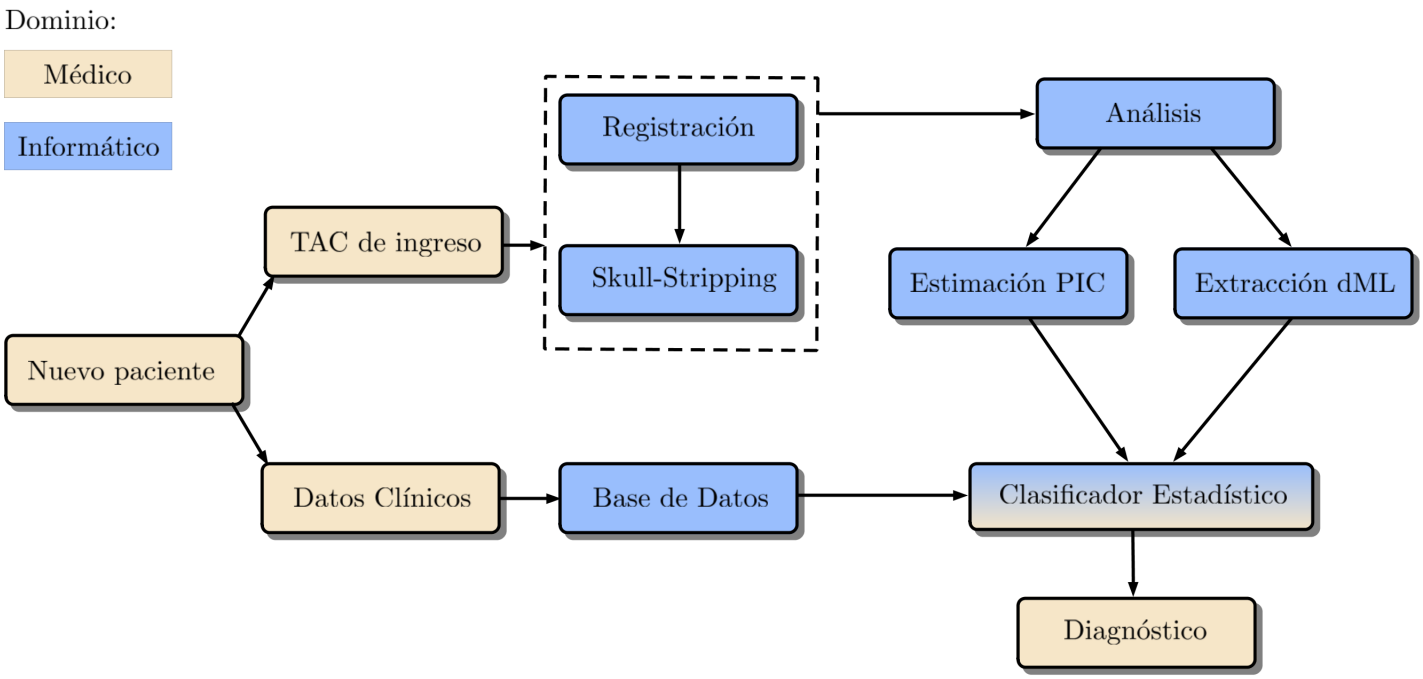


Figura 1.2: Diagrama principal para la predicción del diagnóstico (severidad del trauma).

1.2. Esquema general del trabajo

La Figura 1.2 describe el flujo general de trabajo llevado a cabo en el proyecto, diferenciando las partes de dominio clínico e informático.

1.2.1. Ingreso del paciente

Una vez ingresado el paciente al centro médico, se recopilan los datos clínicos y se realiza el correspondiente estudio tomográfico (llevado a cabo con un tomógrafo, ver Figura 1.4) para obtener la imagen TAC correspondiente (ver Figura 1.3).

1.2.2. Base de datos

Los datos obtenidos del paciente, denominados *variables clínicas* (tales como la edad, sexo, ciertas características de la historia clínica, etcétera), son almacenados en bases de datos informáticas para ser utilizadas posteriormente. En nuestro caso, haremos uso de estos datos, junto con las características extraídas de la imágen TC, para entrenar un clasificador estadístico y poder predecir un diagnóstico, como puede apreciarse en el esquema de la Figura 1.2. La base de datos provista por el hospital HECA para el desarrollo de este proyecto cuenta con 121 casos, de los cuales 29 son pacientes *normales*, y el resto pacientes con algún tipo de



Figura 1.3: Ejemplo de corte axial de una TAC de cráneo.



Figura 1.4: Tomógrafo de última generación AQUILION Lighting 16 disponible actualmente en el HECA. Cuenta con 16 cortes con un espesor de 6mm, tubo generador de rayos X con alta disipación calórica y realiza reconstrucciones 2-D y 3-D. Tiene un costo de alrededor 6 millones de pesos.

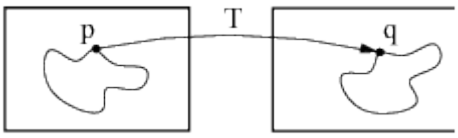


Figura 1.5: La registración de imágenes consiste en encontrar una transformación espacial para mapear una imagen en otra.

trauma, clasificados por los especialistas en leve, moderado y grave.

1.2.3. Preprocesamiento de la imagen TAC: registración y skull-stripping

La primer tomografía que se obtiene de un paciente suele no ser la más adecuada para un análisis exhaustivo, dado que puede estar sujeta a ciertas imperfecciones o artefactos que impiden una correcta apreciación de la imágen. El primer proceso que se realiza, luego de obtener la imagen TAC digitalizada, es el proceso de *registración* (ver Figura 1.5). Registrar una imagen volumétrica es, de algún modo, una traslación de una imagen a un dominio espacial que los profesionales consideren funcional a las necesidades requeridas por el proyecto. Más formalmente, la registración de una imagen es una transformación espacial diseñada para a alinear dos objetos. Para este fin, se emplea un programa existente que registre imágenes, y una *plantilla* que sirve como referencia para que el programa pueda mapear los puntos de una volumen hacia el espacio objetivo. En nuestro caso, se utilizó el programa ANTs[2][1] para normalizar la orientación de la imagen TAC, y se generó la plantilla objetivo (ver Figura 1.6) utilizando los 23 casos normales obtenidos de la base de datos provista, primero normalizando los casos a una plantilla MNI[3] y luego computando el promedio de todas las imágenes obtenidas.

El segundo paso, denominado *skull-stripping*, se utiliza para remover tejido del cráneo que es redundante para el análisis de la imagen y que, una vez removido, facilitará el proceso de extracción de características. Normalmente en el ámbito de la neurociencias y las neuroimágenes, se acostumbra trabajar solo con el tejido cerebral. Si bien esta técnica no fue usada directamente en esta tesina, es una de las etapas comunes de pre-procesamiento para este tipo de imágenes.

1.2.4. Extracción de características

Luego de registrar la imagen, se procede a la extracción de características relevantes (pasos análisis y extracción dML en el diagrama de la Figura 1.2). En este trabajo, se realiza la extracción de la línea media deformada, que permite calcular la desviación de la línea media

[2]Advanced Normalization Tools
[3]Montreal Neurological Institute



Figura 1.6: Plantilla obtenida de los 23 casos normales, visualizada con ITK-Snap desde los tres planos axial, sagital y coronal.

y junto con la estimación del PIC, son de gran importancia para determinar la severidad del trauma. Un ejemplo de esta característica puede observarse en la Figura 1.7.

1.2.5. Clasificación

Una vez extraídas las características de la imagen TAC de cada paciente, junto con las variables clínicas y las etiquetas de cada caso (esto es, la severidad del trauma), se procedió al entrenamiento de un clasificador estadístico para predecir el diagnóstico del paciente. Para

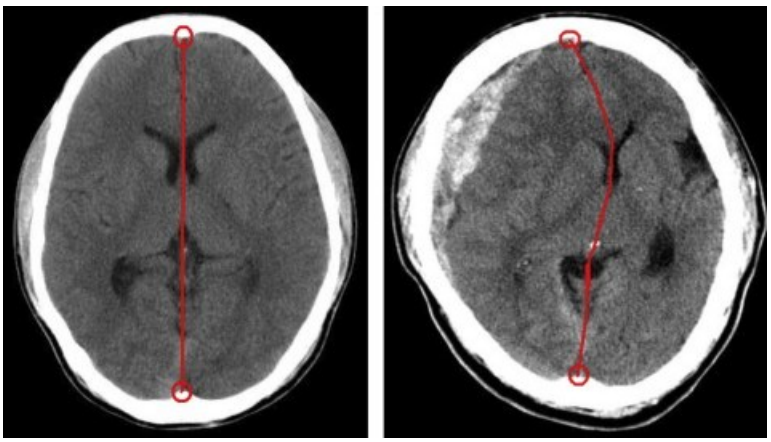


Figura 1.7: A la izquierda un cerebro sano. A la derecha, el mismo cerebro con TCE. En rojo, en la imagen izquierda, se traza la línea media ideal, mientras que a la derecha la deformada.

llevar a cabo este paso, se utilizaron dos técnicas de aprendizaje automatizado: *Random Forest* y *Support Vector Machines*.

Este trabajo propone un método para automatizar el análisis de una imagen TC, incluyendo un método para detectar la línea media ideal y la línea media deformada. Una vez extraídas dichas características de la imagen TAC y mediante el uso de técnicas de aprendizaje automatizado, se buscará entrenar un modelo estadístico para predecir el nivel de gravedad de traumatismos en pacientes con lesiones cerebrales, haciendo más objetiva la decisión del especialista.

Capítulo 2

Terminología médica

En este capítulo se describirán los conceptos anatómicos necesarios para una mejor comprensión del trabajo, incluyendo una breve introducción a *la tomografía axial computada.*

2.1. Cerebro humano

El cerebro es el órgano más importante del sistema nervioso central y es el responsable de regular las acciones y reacciones del cuerpo humano. Se encuentra protegido por el cráneo y se mantiene suspendido en un líquido claro e incoloro llamado líquido cefalorraquídeo o cerebroespinal que actúa como amortiguador de golpes y sacudidas repentinas. El LCR está compuesto mayormente por glóbulos blancos, enzimas y glucosa. El cerebro puede ser descripto a grandes rasgos como la composición de dos tipos de tejidos: materia gris y materia blanca. La materia gris del cerebro está integrada principalmente por somas neuronales y dendritas carentes de mielina junto con células gliales. La materia blanca consiste de fibras nerviosas mielinizadas y se encarga de conectar algunas áreas compuestas de materia gris [12].

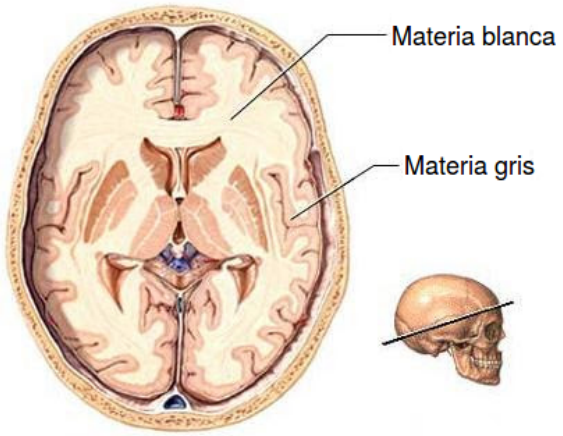


Figura 2.1: Materia gris y blanca de un cerebro humano desde un plano axial.

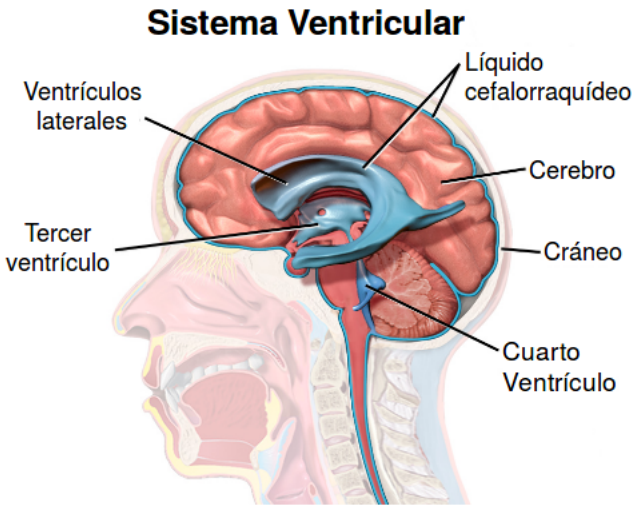


Figura 2.2: Sistema ventricular.

2.2. Líquido Cefalorraquídeo

También denominado *líquido cerebroespinal*, es un líquido incoloro que rodea al cerebro y se encuentra entre medio de los *sulci*, las *fisuras*, las *cisternas basales* y en el centro de los *ventrículos*. Los sulci, junto con las fisuras, cisternas basales y los ventrículos, forman el *espacio subaracnoideo*. El LCR en condiciones normales posee un volumen entre los 100 y 150 ml.

2.3. Sistema Ventricular

Unas de las características relevantes para la extracción de la línea media es la detección de ventrículos. El sistema ventricular (ver Figura 2.2) está formado por cuatro cavidades interconectadas entre sí que contienen LCR y dan soporte a los tejidos del cerebro [11]. Este trabajo se basa en la detección de los ventrículos laterales (ver Figura 2.3) para el trazado de la dML.

2.4. Imágenes Médicas

Actualmente, las tecnologías de imagenología más utilizadas son la *Tomografía Computarizada* (TAC), *Imágenes por Resonancia Magnética* (IRM), *Tomografía por Emisión de Positrones* (TEP) y *Tomografía Computarizada por Emisión Monofotónica* (SPECT) (ver Figura 2.4).

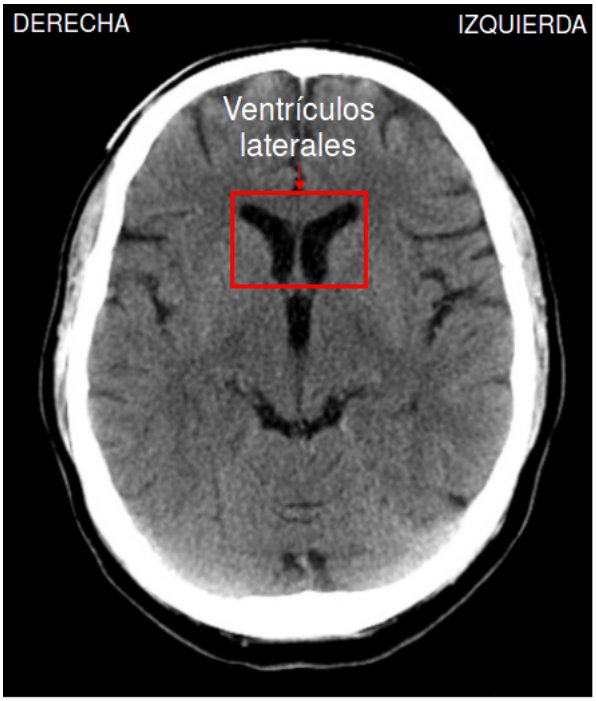
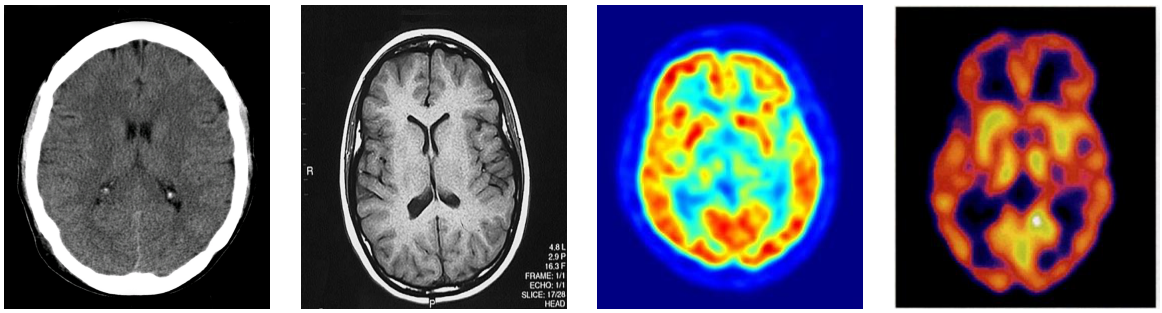


Figura 2.3: Vista desde el plano axial de una TC de los ventrículos laterales.



(a) TAC (b) IRM (c) TEP (d) SPECT

Figura 2.4: Visualización del cerebro a través de distintas modalidades.

El tipo de imagen médica que se utilizará a lo largo de este trabajo es la TAC, debido a que es la modalidad de preferencia en pacientes con estado de salud crítica, condición que requiere de un diagnóstico inmediato y automatizado [6, 9].

2.5. Tomografía Axial Computarizada (TAC)

La Tomografía Axial Computarizada (TAC) es un método de diagnóstico por imágenes que genera imágenes transversales de los órganos internos de un cuerpo mediante el uso de rayos X desde múltiples direcciones alrededor de la región de interés. Las bases matemáticas de las TAC fueron planteadas en 1917 por Johann Radon, (la Transformada de Radon [2]). En lugar de obtener una imagen de proyección, como la radiografía convencional, una TAC

Sustancia	Unidad Hounsfield
Aire	-1000
Grasa	-120
Agua	0
Materia blanca	20-25
Materia gris	30-35
Músculo	+40
Sangre	60-100
Contraste	+130
Hueso	+200

Figura 2.5: Escala Hounsfield.

obtiene múltiples imágenes al efectuar movimientos de rotación alrededor del cuerpo. La representación final de la imagen tomográfica se obtiene mediante la captura de las señales por los detectores y su posterior proceso mediante algoritmos de reconstrucción. En Septiembre de 1971, se introdujo la tomografía computarizada en la práctica médica con un escáner en un paciente con quiste cerebral en el Hospital Atkinson Morley de Londres de forma exitosa. Luego de esto, las TAC fueron el primer método de imagenología que pudo proporcionar información estructural detallada tridimensional de la anatomía de un ser vivo.

Uno de los principales beneficios de las TAC es la facilidad de visualización de estructuras con bajo contraste, lo que hace posible detectar cambios muy pequeños en los tipos de tejido. También, en muchos casos, las imágenes TAC proporcionan información diagnóstica precisa sobre la distribución anatómica en el cuerpo.

En una TAC, se utilizan rayos X para obtener cortes o secciones de los componentes anatómicos en una región deseada del cuerpo. Estos rayos X, al pasar a través de los tejidos, se atenúan en función de las características de los mismos, permitiendo la medición del nivel de atenuación y por lo tanto distinguir distintos tipos de tejidos. Los materiales densos como el hueso presentan una mayor atenuación en comparación con los tejidos blandos como la materia gris. El nivel de atenuación de los tejidos se mide en Unidades Hounsfield (UH). La tabla de la Figura 2.5 muestra los valores de atenuación de las sustancias más comunes presentes en el cuerpo humano. En las tomografías computarizadas, un alto nivel de UH corresponde a mayor intensidad y por lo tanto las estructuras óseas (+200 UH) aparecen más brillantes que los tejidos (20-35 UH).

2.6. Orientación

Las tomografías del cerebro son comunmente visualizadas desde abajo, como observando hacia la parte superior de la cabeza. Esto implica que el lado derecho del cerebro del paciente se encuentra en el lado izquierdo del observador, y viceversa. La parte anterior de

la cabeza está situada en la parte superior de la imagen, como se puede apreciar en la Figura 2.6.

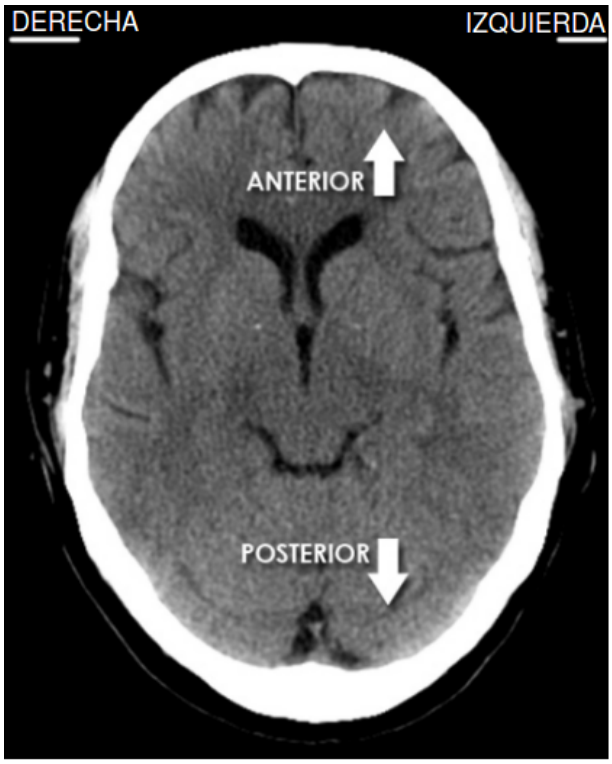


Figura 2.6: Orientación del cerebro en una tomografía computada. Nótese como el lado izquierdo y derecho de la imagen se ven opuestos en una TC.

2.7. Huesos del cráneo y suturas

El cerebro está localizado dentro de la bóveda craneal, un espacio formado por huesos del cráneo y la base craneal. Todo lo que se encuentra dentro de la bóveda craneal se denomina *intra craneal*; todo lo demás es *extra craneal*.

Los huesos del cráneo y de la base del cráneo (huesos frontales, parietales, occipitales, etmoides, esfenoides y temporales) se osifican por separado y gradualmente se unen en las suturas del cráneo. El cráneo tiene tablas internas y externas de hueso cortical con hueso esponjoso central llamado *diploe* (ver Figura 2.7). Se puede notar la apariencia irregular de las suturas del cráneo, que no deben ser confundidas con fracturas que son típicamente rectas.

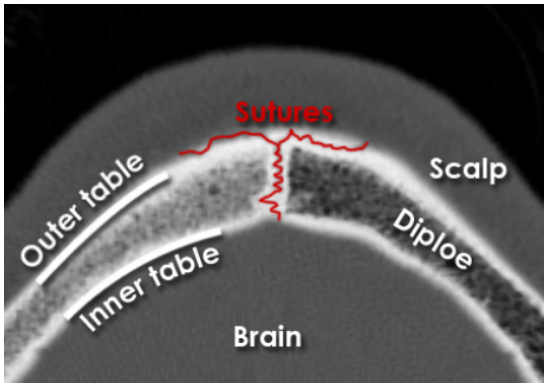


Figura 2.7: Estructura ósea del cráneo. Algunos términos están en Inglés.

2.8. Traumatismo Craneoencefálico

El TCE es un daño no degenerativo y no congénito al cerebro por parte de una fuerza mecánica externa, que posiblemente lleva a un deterioro permanente o temporal de las funciones cognitivas, físicas y psicosociales, con un estado de conciencia asociado disminuido o alterado.

Puesto que nuestro cerebro define quiénes somos, las consecuencias de una lesión cerebral pueden afectar todos los aspectos de nuestras vidas, incluyendo nuestra personalidad. Una lesión cerebral es diferente al de una extremidad o un pulmón. Una lesión en estas áreas limita el uso de una parte específica del cuerpo, pero la personalidad y habilidades mentales permanecen inalteradas. Muy a menudo, estas estructuras corporales sanan y recuperan la función que tenían antes.

Las lesiones cerebrales no sanan como otras lesiones. La recuperación es funcional, basada en mecanismos que en algunos casos son inciertos. No hay dos lesiones cerebrales iguales y las consecuencias de dos lesiones similares puede ser muy diferentes.

La Figura 2.8 muestra un ejemplo de una serie de imágenes axiales de una TC con un TCE. Las anomalías que los radiólogos a menudo observan desde las imágenes TC con traumatismos incluyen hemorragias (hematomas), desplazamiento de la línea media, derrames de la cisterna basal, edemas, etcétera.

2.9. Escala de Glasgow

Existen diferentes escalas que los médicos utilizan para cuantificar los síntomas de un TCE. Esta sección discute la *Escala de Glasgow*.

La Escala de Coma de Glasgow (Figura 2.9) se basa en una escala de 15 puntos para cuantificar y categorizar los resultados de la lesión cerebral en base a la capacidad social

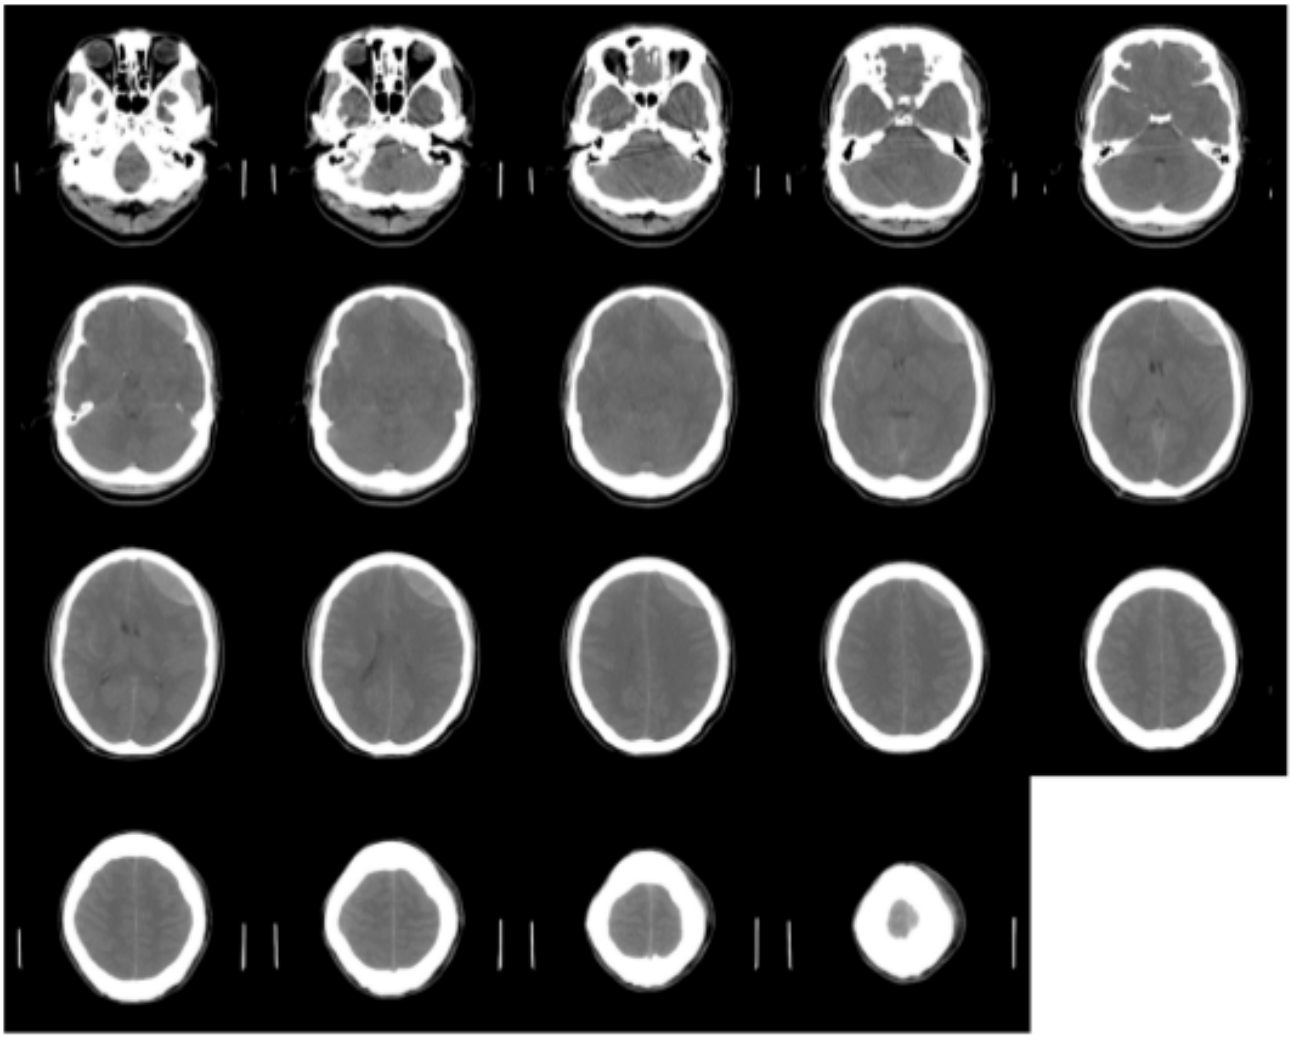


Figura 2.8: Cortes axiales de una TC de un cerebro con un traumatismo craneoencefálico.

general o la dependencia de otros. La prueba mide la respuesta en tres categorías: motora, verbal y de apertura ocular. Los valores parciales de cada categoría se adicionan para obtener el puntaje total que determina la severidad del trauma de acuerdo a la tabla mostrada en la Figura 2.10.

Variable	Respuesta	Puntaje
Apertura ocular	Espontánea	4
	A la orden	3
	Ante un estímulo doloroso	2
	Ausencia de apertura ocular	1
Respuesta verbal	Orientado correctamente	5
	Paciente confuso	4
	Lenguaje inapropiado	3
	Lenguaje incomprensible ocular	2
	Carencia de actividad verbal	1
Respuesta motora	Obedece órdenes correctamente	6
	Localiza estímulos dolorosos	5
	Realiza movimientos de retracción al dolor	4
	Respuesta con flexión anormal de los miembros	3
	Respuesta con extensión anormal de los miembros	2
	Ausencia de respuesta motora	1

Figura 2.9: Tabla de puntajes de la Escala de Glasgow.

2.10. Hipótesis de Monro-Kellie

Hace más de dos siglos, Alexander Monro aplicó algunos de los principios de la física a los contenidos intracraneales y por primera vez planteó la hipótesis de que la sangre que circulaba en el cráneo era de volumen constante en todo momento, apoyado por los experimentos de Kellie. En líneas generales, la hipótesis plantea que el cráneo y los volúmenes de sus componentes principales (sangre, LCR y tejido cerebral) están en constante equilibrio, haciendo que un incremento en el volumen en uno de estos componentes será compensado con una reducción en el volumen de otro. A través de esta hipótesis, las lesiones que ocupan espacio (por ejemplo hematomas, tumores, abscesos, etcétera) puede causar cambios cerebrales locales o globales como desviación de la línea media, aumento en la presión intracraneal (PIC), compresión del tronco encefálico y la muerte.

Puntaje	Interpretación
14 - 15	Traumatismo craneoencefálico leve
9 - 13	Traumatismo craneoencefálico moderado
< 9	Traumatismo craneoencefálico grave

Figura 2.10: Interpretación del trauma de acuerdo al puntaje obtenido.

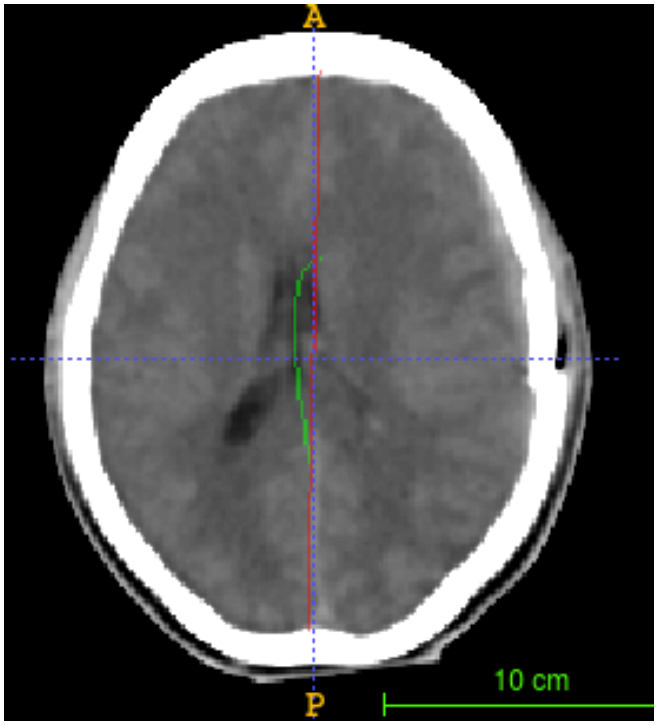


Figura 2.11: Un ejemplo de una TC con TCE. La iML detectada trazada en rojo, mientras que la dML está coloreada en verde.

2.11. Presión Intracraneal

La presión intracraneal es la presión dentro del cráneo y, por lo tanto, en el tejido cerebral y el líquido cefalorraquídeo. El PIC se mide en milímetros de mercurio (mmHg) y, en reposo, es normalmente de 7-15 mmHg para un adulto.

2.12. Desviación de la Línea Media

La desviación de la línea media (MLS, por su denominación en inglés *mid-line shift*) es una de las características más importantes a tener en cuenta para la evaluación de la severidad del trauma de un cerebro.

La línea media ideal, la cual nos referiremos como *iML* (por su nombre en inglés *ideal mid-line*) en el resto del trabajo, es una línea vertical que divide al cerebro en dos partes *casi* simétricas. El desvío de la iML es causado por diversos traumatismos, lo que causa una deformidad en la línea media y por lo tanto se obtiene una *dML* (*deformed mid-line*), como puede observarse en la Figura 2.11. La MLS propiamente dicha se mide en milimetros y es la máxima distancia perpendicular entre la iML y la dML.

Capítulo 3

Conceptos Generales

El propósito de este capítulo es proporcionar al lector un vistazo general de los conceptos computacionales requeridos para poder entender del trabajo. Primero se dará una introducción al Aprendizaje Automatizado y, finalmente, se describirán dos algoritmos denominados *Support Vector Machines* y *Random Forest* utilizados en el proyecto para la clasificación de los datos.

3.1. Aprendizaje Automatizado

La Real Academia Española define *aprender* como: "adquirir el conocimiento de algo por medio del estudio o de la experiencia" [13]. Resulta interesante preguntarse, dentro del área de las ciencias de la computación, ¿cómo creamos programas que aprendan a través de la experiencia?

Resulta que, en 1997, Tom Mitchel respondió más formalmente esta pregunta con la siguiente definición:

Definición 3.1.1. Se dice que un programa **aprende** de la experiencia E con respecto a cierto tipo de tareas T y una medida de desempeño P, si el desempeño en tareas de T según la medida P, mejora con la experiencia E [10].

El Aprendizaje Automatizado (*Machine Learning* por su nombre en inglés) es una rama de la inteligencia artificial que tiene como objetivo principal que las computadoras sean capaces de realizar lo que es natural para los humanos y animales: aprender de la experiencia. Los métodos de aprendizaje desarrollados en el área usan algoritmos computacionales que permiten "aprender"directamente de los datos sin depender de un modelo previo.

3.1.1. Elementos del aprendizaje automatizado

En términos más formales, un algoritmo de aprendizaje automatizado tiene como objetivo encontrar una función

$$h : X \to Y \tag{3.1}$$

usualmente denominada *hipótesis* o *clasificador*, tal que aproxime una función ideal $f : X \to Y$

$$h \approx f \tag{3.2}$$

La hipótesis h mapea elementos del dominio X de variables de entrada (también conocidos como características, predictores o variables independientes), a valores del conjunto Y de valores de respuesta (usualmente denominadas *etiquetas*, o variables dependientes). El algoritmo de aprendizaje trabaja sobre un conjunto de datos $\mathcal{D}$, llamado conjunto de entrenamiento. Dependiendo del tipo de problema, $\mathcal{D}$ puede ser un subconjunto de los siguientes dominios:

- $\mathcal{D} = \{x_1, x_2, ..., x_n\} \subseteq X$ NO SUPERVISADO
- $\mathcal{D} = \{(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)\} \subseteq X \times Y$ SUPERVISADO

3.1.2. ¿Para qué estimar f?

Existen dos razones: *predicción* e *inferencia*.

- PREDICCIÓN
  El objetivo es la obtención de un clasificador estadístico h que permita la predicción del valor de salida para las observaciones no presentes en el conjunto de datos de entrenamiento. En muchas situaciones, tenemos un conjunto de datos X sin sus resultados Y. En este caso, se tiene

  $$\hat{Y} = h(X), \tag{3.3}$$

  donde h representa nuestra estimación de f, e $\hat{Y}$ es el resultado de la predicción para valores de X .

- INFERENCIA
  En ciertos casos particulares, nos interesa estimar f, no para hacer predicciones sobre Y, sino para entender la relación entre X e Y, o más específicamente, estudiar cómo Y cambia en función de los parámetros de entrada $x_i, i = 1, .., n$.

En escencia, el aprendizaje automatizado consiste en un conjunto de técnicas y métodos para estimar f.

3.1.3. Aprendizaje Supervisado versus No Supervisado

De los distintos dominios posibles para el conjunto de entrenamiento $\mathcal{D}$, se diferencian dos tipos de aprendizajes:

- SUPERVISADO
  Para cada observación $x_i \in X, i = 1, ..., n$ del conjunto de datos de entrenamiento $\mathcal{D}$, existe una respuesta asociada $y_i \in Y$. Se desea ajustar un modelo que relacione de alguna manera los elementos de entrenamiento, con el objetivo de predecir la respuesta de futuras observaciones (predicción) o entender mejor la relación entre las etiquetas y las variables de entrada (inferencia). Muchos de los métodos de aprendizaje clásicos como regresión lineal y regresión lógistica, y algunos más modernos como *Support Vector Machines*, operan en el dominio del aprendizaje supervisado.

- NO SUPERVISADO
  En contraste, el aprendizaje no supervisado describe una situación un poco más desafiante, donde para cada entrada $i = 1, ..., n$ se observa un vector de variables $x_i \in X$ pero no una respuesta asociada $y_i \in Y$. Con esta configuración, se trabaja como si fuese una caja negra: se denomina *no supervisado* porque se carece de una variable de respuesta que pueda supervisar el análisis. Una de las técnicas más utilizadas en esta área es el análisis de clústers, o *clustering*.

3.1.4. Aprendizaje Supervisado

En cada proceso de Aprendizaje Supervisado puede encontrarse las siguientes etapas:

- ADQUISICIÓN DE DATOS
  Se obtiene el conjunto de datos (información, imágenes, videos, etcétera) sobre el cual se realizarán los experimentos de aprendizaje.

- PREPROCESAMIENTO
  Los datos de entrada se preprocesan eliminando redunancia, completando información faltante y normalizando.

- ENTRENAMIENTO
  Se define una métrica para el error del método, y se usa una porción de los datos para ajustar los parámetros del modelo, minimizando el error.

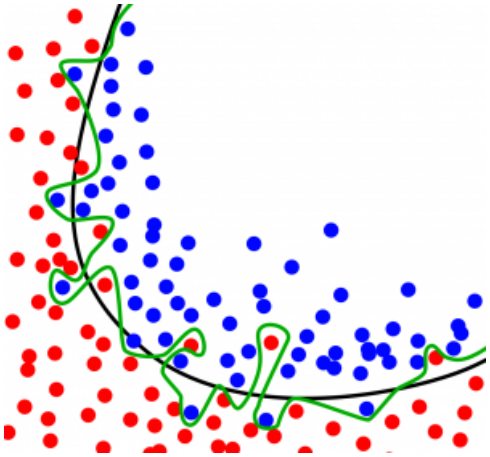


Figura 3.1: La curva de color verde intenta ajustar los datos perfectamente, haciendo que el modelo obtenido sea muy específico a los datos de entrenamiento y no generalice bien a observaciones nuevas. En contraste, la curva de color negro comete más errores, pero aproxima un modelo más generalizable.

- TESTING O GENERALIZACIÓN
  Se usa otra porción de los datos (diferente a la que se utiliza en la etapa anterior) para medir la capacidad de generalización del método en datos no vistos hasta ahora.

3.1.5. Sobreajuste

En Aprendizaje Automatizado, podemos diferenciar tres conjuntos de datos: entrenamiento, test y validación. Está claro de lo explicado previamente cómo se utilizan los dos primeros, mientras que el conjunto de validación servirá durante el entrenamiento para aproximar el error de test. Es decir, queremos estimar el error que obtendremos cuando entrenemos el modelo definitivamente. Además, este error nos servirá como referencia para ajustar los parámetros del modelo. En muchos casos, puede ocurrir que el modelo se ajuste demasiado a los datos de entrenamiento, tanto así que aprende conceptos específicos del conjunto de entrenamiento y no generalice bien al momento de predecir sobre el conjunto de test. Este último problema se conoce como sobreajuste (*overfitting*) y afecta a gran parte de los métodos de aprendizaje supervisado. En la Figura 3.1 se puede ver un caso de sobreajuste, y la consecuencia en las gráficas de errores en la Figura 3.2.

3.1.6. Validación cruzada

La técnica de validación cruzada (*cross-validation*) consiste en dividir un conjunto de datos en subconjuntos de tal forma que el entrenamiento es realizado en algunos de ellos, mientras que los restantes son usados para validar y confirmar el análisis inicial. En la validación cruzada de k iteraciones (*k-fold cross-validation*) los datos de muestra se dividen en k parti-

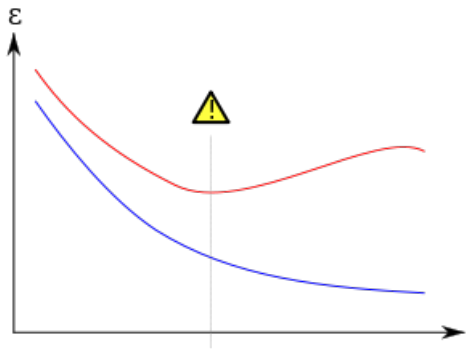


Figura 3.2: Lo que termina sucediendo cuando existe sobreajuste es que el error de entrenamiento (curva azul) disminuye considerablemente, mientras que el error de test (curva roja) aumenta.

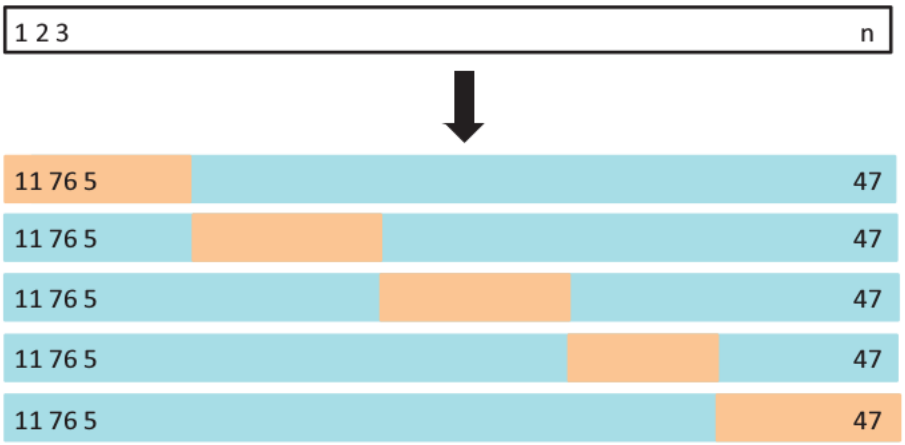


Figura 3.3: Ejemplo de validación cruzada de 5 iteraciones. Un conjunto de n observaciones es dividido aleatoriamente en cinco grupos no superpuestos. Los grupos de color naranja actúan como validación, mientras que los celestes como entrenamiento.

ciones (ver Figura 3.3). Uno de los subconjuntos se utiliza como datos de prueba y los $k-1$ restantes como datos de entrenamiento. El proceso de validación cruzada es repetido durante k iteraciones, con cada uno de los posibles subconjuntos de datos de prueba. Finalmente se realiza la media aritmética de los resultados de cada iteración para obtener un único resultado.

3.1.7. Sesgo inductivo

Otro concepto interesante es el de *sesgo inductivo*, también conocido como *sesgo de aprendizaje*. Este término se refiere al conjunto de hipótesis o suposiciones que el método de aprendizaje utiliza para realizar predicciones en base a los casos no vistos todavía. Un ejemplo clásico de sesgo inductivo es conocido como *la navaja de Occam*, que determina que siempre debe preferirse la hipótesis más simple consistente con los datos.

3.1.8. Problemas de Clasificación versus Regresión

Las variables de entrada pueden ser clasificadas como *cuantitativas* o *cualitativas* (también conocidas como categóricas). Las variables cuantitativas toman valores numéricos, por ejemplo, la edad de una persona, altura, peso, o salario, el precio de una casa, etcétera. En contraste, las variables cualitativas toman valores de una de las K clases o categorías diferentes. Como ejemplos se puede nombrar el sexo de una persona (masculino o femenino), la marca de un producto (Marca A, B o C), el diagnóstico de una enfermedad (Hepatitis tipo A, tipo B, tipo C). Aquellos problemas que tengan un dominio Y cuyos valores sean cuantitativos, se denominan problemas de *regresión*, mientras que los que involucren una respuesta cualitativa, son conocidos como problemas de *clasificación*.

3.2. Estimando f: Métodos de Aprendizaje

Las observaciones, i.e., variables de entradas tomadas del conjunto $\mathcal{D}$ se denominan *datos de entrenamiento*, dado que serán utilizadas para entrenar, o enseñar, a un método de aprendizaje, cómo estimar f. En esta sección se describirán con cierto detalle dos de estos métodos.

3.2.1. Máquinas de Vectores de Soporte

Las *máquinas de vectores de soporte* (*Support Vector Machines* o *SVMs*) es una técnica para clasificación que fue desarrollado en el área de las ciencias de la computación en los 90s por *Vladimir N. Vapnik et al* [14] y cuya popularidad ha crecido bastante desde entonces.
Como ejemplo introductorio, considere un problema de clasificación separable en un espacio de dos dimensiones. Supongamos el conjunto de entrenamiento $\mathcal{D}$ de la forma:

$$\mathcal{D} = \{(x_i, y_i) \mid x_i \in \mathbb{R}, y_i \in \{1, -1\}\}_{i=1}^{n}$$

- HIPERPLANOS
  En un espacio de dimensión p, un hiperplano es un subespacio plano de dimensión $p-1$. Por ejemplo, en dos dimensiones, un hiperplano es una línea recta que divide al plano cartesiano en dos partes. La definición matemática generalizada para un hiperplano de dimensión p está dada por la ecuación

  $$\beta_0 + \beta_1 x_1 + ... + \beta_p x_p = 0 \tag{3.4}$$

  En otras palabras, para cada $x = (x_1, ..., x_p) \in X$ que verifica (3.4) es un punto del hiperplano. Un hiperplano de dos dimensiones puede observarse en la Figura 3.4.

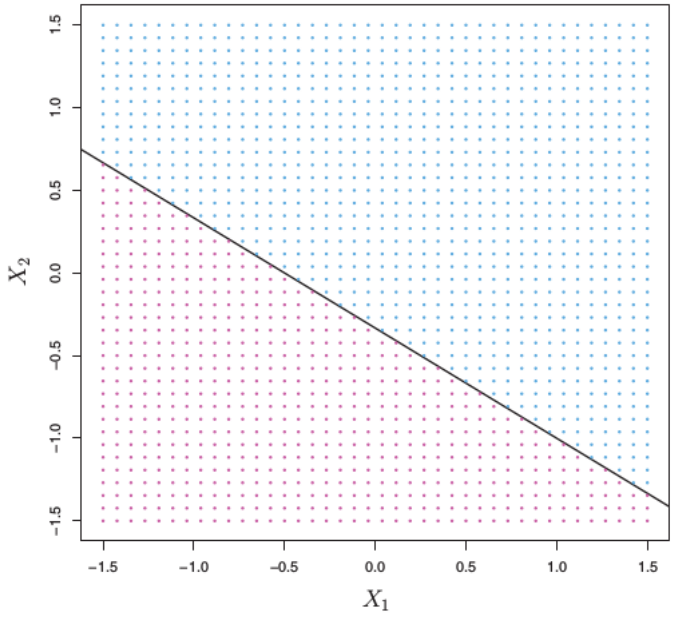


Figura 3.4: El hiperplano en 2 dimensiones $1 + 2X_1 + 3X_2 = 0$. La región azul es el conjunto de puntos para los cuales $1 + 2X_1 + 3X_2 > 0$, la región violeta $1 + 2X_1 + 3X_2 < 0$.

- CLASIFICACIÓN USANDO UN HIPERPLANO

  Supongamos que se tienen n datos de entrenamiento $(x_{i1}, ..., x_{ip})$ $i = 1, ..., n$ en un espacio p-dimensional, y que estos valores pertenecen a dos clases distintas $y_1, ..., y_n \in Y = \{-1, 1\}$. También se dispone un elemento del conjunto test $x^* = (x_1^*, ..., x_p^*)$. Se asume también que es posible construir un hiperplano que separa exactamente los valores de entrenamiento de acuerdo a las etiquetas de Y. Se pueden apreciar tres ejemplos en el panel de la izquierda en la Figura 3.5.

  Un hiperplano separador tiene las siguientes propiedades

$$\beta_0 + \beta_1 x_{i1} + ... + \beta_p x_{ip} > 0 \text{ si } y_i = 1, \tag{3.5}$$

  y

$$\beta_0 + \beta_1 x_{i1} + ... + \beta_p x_{ip} < 0 \text{ si } y_i = -1. \tag{3.6}$$

  Equivalentemente, se tiene:

$$y_i(\beta_0 + \beta_1 x_{i1} + ... + \beta_p x_{ip}) > 0. \tag{3.7}$$

  para $i = 1, ..., n$.

  Al asumirse que existe el hiperplano separador ideal, podemos usarlo para generar un clasificador que intuititvamente separa los parámetros de entrada dependiendo de qué lado del hiperplano se encuentra, i.e., utilizando las ecuaciones (3.5) y (3.6). Sea

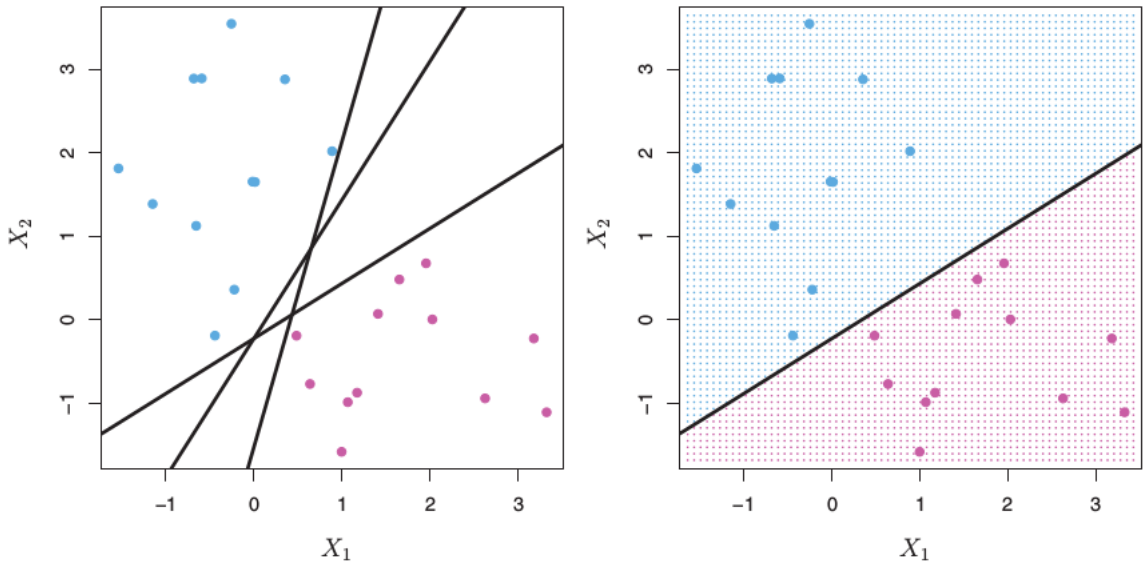


Figura 3.5: A la izquierda: dos clases de etiquetas, en azul y violeta. Se muestran tres hiperplanos separadores de ejemplo (hay infinitas posibilidades) en color negro. A la derecha: se muestra un hiperplano separador junto a las grillas de colores azul y violeta que indican la decisión tomada por un clasificador basado en dicho hiperplano para clasificar los puntos.

$$h(x^*) = \beta_0 + \beta_1 x^*_{i1} + ... + \beta_p x^*_{ip}$$

$$h(x^*) = \begin{cases} 1 & \text{si } n \text{ es} > 0 \\ -1 & \text{si } n \text{ es} < 0 \end{cases} \tag{3.8}$$

Si $h(x^*) \gg 0$ o $h(x^*) \ll 0$ entonces podemos confiar que el punto fue clasificado correctamente. En caso de $h(x^*) \approx 0$, x^* se encuentra cerca del hiperplano por lo tanto es más difícil asegurar con certeza la clase de x^*.

- MAXIMIZANDO EL MARGEN

  En general, si los datos que se tienen disponibles pueden ser perfectamente separados por un hiperplano, entonces existirán infinitas posibilidades (recordemos que de (3.4) se tiene que $\beta_i \in \mathbb{R}, i = 1, ..., p$). Podemos ver un ejemplo de esto en la Figura 3.5 a la izquierda: esto se da porque siempre se podrá mover o rotar una recta un poco y se obtendrá otro posible hiperplano separador. Entonces se debe encontrar una manera razonable de decidir cual elegir. Una elección natural es el *hiperplano de máximo margen*, que es el hiperplano que se encuentra perpendicularmente más alejado de los puntos más extremos de cada clase, como puede observarse en la Figura 3.6. Se espera que el clasificador tenga el mismo margen para los casos de test.

- OBTENIENDO EL HIPERPLANO DE MÁXIMO MARGEN

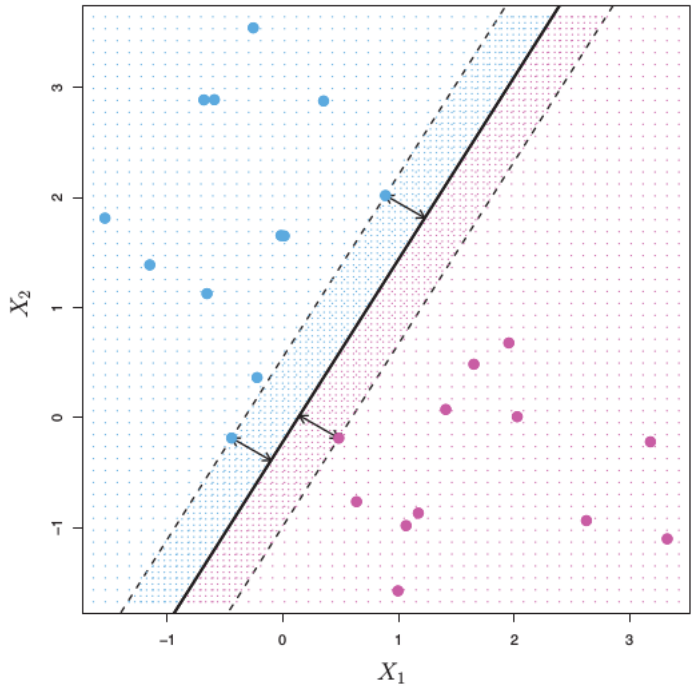


Figura 3.6: Se aprecian dos clases de puntos: azules y violetas. El hiperplano de margen máximo se muestra como una línea negra sólida. El margen es la distancia entre el hiperplano y cada una de las líneas punteadas. Los dos puntos azules y el punto violeta son los *vectores de soporte*, y la distancia de dichos puntos al hiperplano se muestra con una flecha.

Brevemente, el hiperplano de máximo margen es el resultado del siguiente problema de optimización:

$$\begin{aligned} \min_{\beta_0, \beta_1, \ldots, \beta_p} \quad & M \\ \text{s.t.} \quad & \sum_{j=1}^{p} \beta_j^2 = 1, \\ & y_i(\beta_0 + \beta_1 x_{i1} + \ldots + \beta_p x_{ip}) \geq M, \quad i = 1, \ldots, n \end{aligned}$$

- CLASIFICADORES DE VECTORES DE SOPORTE

  Un clasificador de máximo margen es una forma natural de clasificar un conjunto de datos, si el hiperplano separador en cuestión existe. En el caso de la Figura 3.7, no podemos separar las clases exactamente por un hiperplano, por lo que en esta ocasión estaríamos dispuestos a considerar un clasificador basado solamente en un hiperplano que no separe perfectamente las dos clases, en interés de obtener:

  - Más robustez a observaciones individuales
  - Mejor clasificación de la mayoría de las observaciones de entrenamiento

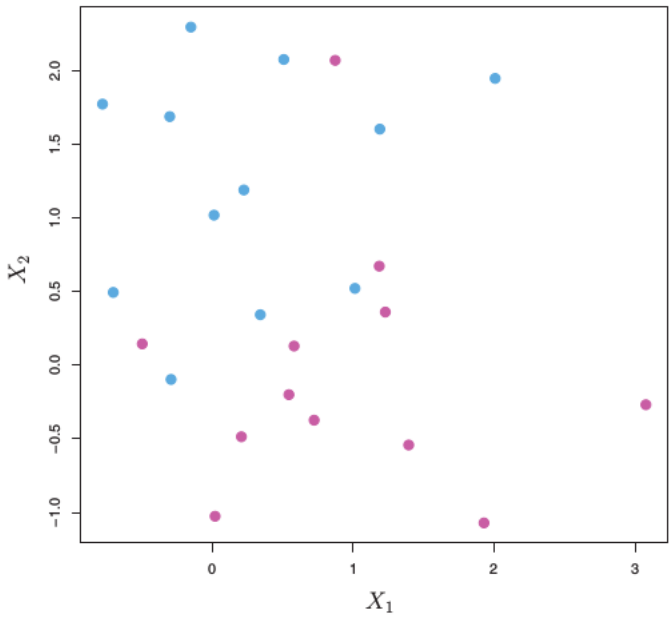


Figura 3.7: Dos clases de observaciones, azules y violetas. En este caso, ambas clases no pueden ser separadas por un hiperplano, lo que implica que no podemos usar un clasificador de máximo margen.

Un *clasificador de vector de soporte* (*CVS*) logra exactamente esto. En vez de encontrar el margen más extenso para que cada observación esté no solo en el lado correcto del hiperplano sino también en el lado correcto del margen, se permite que algunas observaciones queden en el lado incorrecto del margen, y también en el lado incorrecto del hiperplano. Un ejemplo puede verse en la Figura 3.8. Básicamente, un CVS es el resultado del siguiente problema de optimización:

$$\begin{aligned} \min_{\beta_0, \beta_1, \ldots, \beta_p, \epsilon_1, \ldots, \epsilon_n} \quad & M \\ \text{s.t.} \quad & \sum_{j=1}^{p} \beta_j^2 = 1, \\ & y_i(\beta_0 + \beta_1 x_{i1} + ... + \beta_p x_{ip}) \geq M(1 - \epsilon_i), \quad i = 1, \ldots, n, \\ & \epsilon_i \geq 0, \\ & \sum_{i=1}^{n} \epsilon_i \leq C, \end{aligned}$$

siendo C un parámetro de ajuste y M el ancho del márgen. $\epsilon_1, \ldots, \epsilon_n$ son *variables slack*, las cuales permiten que observaciones individuales se mantengan del lado incorrecto del márgen. Si $\epsilon_i > 0$ entonces la i-ésima observación se encuentra en el lado incorrecto del margen y ocurre una violación; si $\epsilon_i > 1$, dicha observación se encuentra en el lado incorrecto del hiperplano. Si $\epsilon_i = 0$, la i-ésima observación se encuentra en el

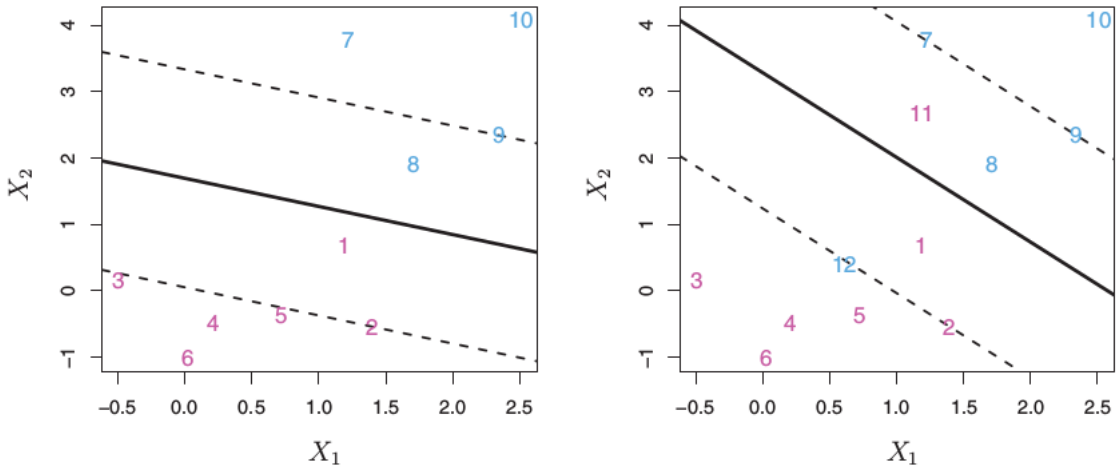


Figura 3.8: Izquierda: el hiperplano se muestra con la línea sólida y los márgenes como líneas punteadas. Las observaciones violetas 3, 4, 5 y 6 se encuentran en el lado correcto del margen, la observación 2 se encuentra exactamente sobre el margen, y la observación 1 está del lado incorrecto del mismo. Las observaciones azules 7 y 10 están del lado correcto del margen, 9 está sobre el margen y 8 en el lado incorrecto del margen. No se encuentran observaciones en el lado incorrecto del hiperplano. Derecha: lo mismo que en el ejemplo de la izquierda salvo que se agregan dos observaciones más, 11 y 12, que se encuentran ambas en el lado incorrecto del margen e hiperplano.

lado correcto del margen. Una vez resuelto el problema de optimización, se clasifica una observacion x^* determinando en qué lado del hiperplano se encuentra, es decir, basándonos en el signo de $f(x^*) = \beta_0 + \beta_1 x_1^* + \ldots + \beta_p x_p^*$. En la práctica, C es un parámetro que se ajusta mediante validación cruzada y dadas las restricciones del problema de optimización, determina la tolerancia a las violaciones del márgen: si C incrementa el márgen se expande; si decrece, el márgen se reduce. El problema de optimización anterior tiene una propiedad interesante: solo las observaciones que se mantienen sobre el margen o que violan el mismo afectan el hiperplano, y en consecuencia el clasificador obtenido. En otras palabras, una observación que estrictamente se encuentra en el lado correcto del margen no afecta el clasificador de vector de soporte. Las observaciones que sí afectan al clasificador se denominan *vectores de soporte*.

- MÁQUINAS DE VECTORES DE SOPORTE

  Las *SVM* son una mejora del *CVS* que resulta de la extensión del espacio de características utilizando *kernels* para trazar una separación no lineal entre las clases y lidiar con el problema de la Figura 3.9.
  Se puede demostrar que un CVS puede ser representado por la siguiente expresión

$$f(x) = \beta_0 + \sum_{i=1}^{n} \alpha_i \langle x, x_i \rangle, \tag{3.9}$$

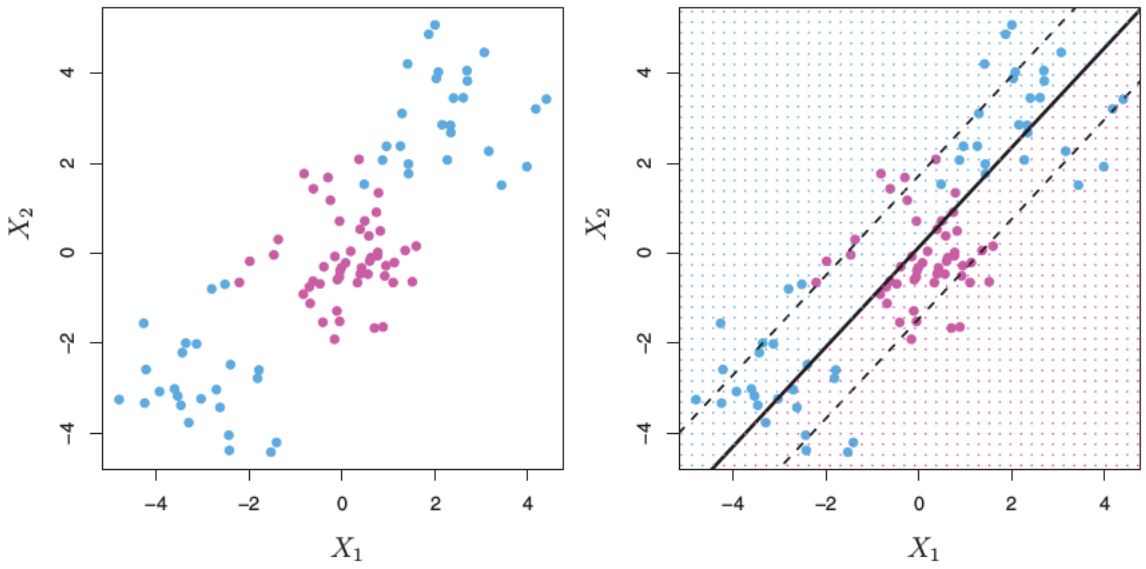


Figura 3.9: Izquierda: las observaciones tienen dos clases no linealmente separables. Derecha: el clasificador de vector de soporte busca encontrar un límite lineal y en consecuencia su desempeño es bastante pobre.

donde el producto interno está definido como

$$\langle x_i, x_i' \rangle = \sum_{j=1}^{p} x_{ij} x_{i'j}. \tag{3.10}$$

Se define una generalización del producto interno de la forma

$$K(x_i, x_i'), \tag{3.11}$$

donde K es una función llamada *kernel* la cual cuantifica la similaridad de dos observaciones, x_i y x_i'. Por ejemplo, podríamos tomar

$$K(x_i, x_i') = \sum_{j=1}^{p} x_{ij} x_{i'j}, \tag{3.12}$$

lo cual es equivalente a un clasificador de vector de soporte. La ecuación 3.12 define un kernel *lineal*. Sin embargo, pueden tomarse distintas métricas para la ecuación 3.11. Si se reemplazara K con

$$K(x_i, x_i') = (1 + \sum_{j=1}^{p} x_{ij} x_{i'j})^d, \tag{3.13}$$

se obtendría un kernel *polinomial* de grado d, donde d es un entero positivo. Usando $d > 1$ en vez del kernel lineal estándar (3.12), se obtienen límites de decisión mucho más flexibles, dado que se ajusta un CVS en un espacio dimensional más grande abarcando polinomios de grado d. Cuando un CVS es combinado con un *kernel no lineal* como el

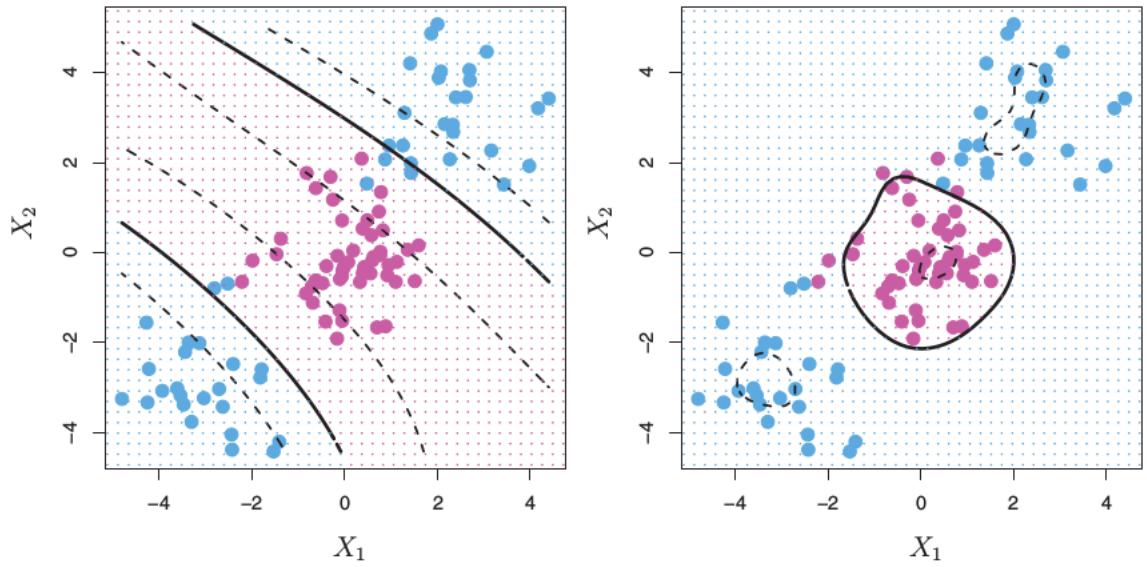


Figura 3.10: A la izquierda se observa un SVM con kernel polinomial de grado 3 aplicado a los datos de la Figura 3.9, resultando en una regla decisión más apropiada. A la derecha, un SVM con kernel radial. Ambos ejemplos logran un buen desempeño sobre el conjunto de datos.

de la ecuación 3.13, se obtiene un SVM. Entre otras alternativas de elección de kernels, se encuentra el *kernel radial*, definido como

$$K(x_i, x_i') = exp(-\gamma \sum_{j=1}^{p} (x_{ij} - x_{i'j})^2), \tag{3.14}$$

siendo γ una constante positiva. En la Figura 3.10 se muestra un ejemplo de un SVM con un kernel radial dando un buen resultado en la clasificación.

3.2.2. Árboles de Decisión

En esta sección se describen métodos basados en árboles para problemas de regresión y clasificación. Estas técnicas implican segmentar el dominio en diferentes regiones para realizar predicciones. Dado que las reglas de decisión utilizadas segmentan el espacio de valores para las variables de entrada en forma de árbol, este tipo de enfoque se conoce como métodos de árboles de decisión [10]. Estos métodos son simples y útiles para interpretar resultados. Sin embargo, no son competitivos con otros métodos de aprendizaje supervisado más avanzados, como SVM. Es por ello que también se introducen técnicas como *Bagging* y *Random Forest*, que implementan mejoras notables combinando múltiples árboles de decisión y realizando predicciones en base a consensos. Los árboles de decisión (*decision trees*) pueden ser aplicados tanto a problemas de regresión como clasificación.

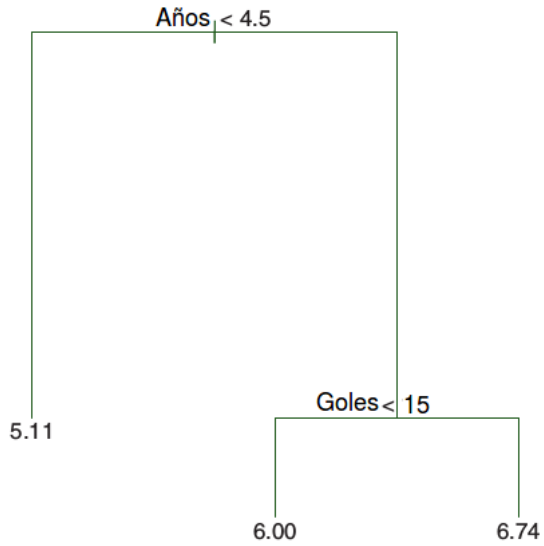


Figura 3.11: Árbol de regresión generado para los datos de una base de datos de fútbol para predecir el salario (anual en millones de dólares) basado en la cantidad de años de experiencia y la cantidad de goles marcados en el último año. El árbol tiene dos nodos internos y tres nodos hoja. El valor de cada nodo hoja es el promedio de todos los resultados de cada observación de entrenamiento en la región.

- ÁRBOLES DE REGRESIÓN
  Como motivación, empezamos con un ejemplo simple: predecir el salario de un jugador de fútbol basado en dos variables

  - *Años*: el número de años que jugó en primera
  - *Goles*: el número de *goles* que hizo el año anterior

  La Figura 3.11 muestra un árbol de regresión para el conjunto de datos. Básicamente, consiste en una serie de reglas de corte que comienzan en la raíz del árbol. El corte superior asigna a los jugadores que tengan menos de $4{,}5$ años a la rama izquierda, y en el otro caso a la derecha. El salario que se asigna a los jugadores presentes en la rama izquierda es el promedio de todos los salarios que tengan menos de $4{,}5$ años. Los jugadores que tengan más de $4{,}5$ años (en la rama derecha), son divididos a su vez de acuerdo a los goles marcados. En total, el árbol segmenta a los jugadores en tres regiones: $R1 = \{X \mid Años < 4{,}5\}$, $R2 = \{X \mid Años \geq 4{,}5, Goles < 15\}$, y $R3 = \{X \mid Años \geq 4{,}5, Goles \geq 15\}$. Estas regiones se conocen como nodos hoja o nodos terminales en la representación en forma de árbol (ver Figura 3.12).

  Del árbol de regresión mostrado en la Figura 3.11 se puede interpretar que *Años* es la variable más importante para determinar el salario de un jugador, y los jugadores como menos experiencia ganan menos que aquellos más experimentados. Dado un jugador

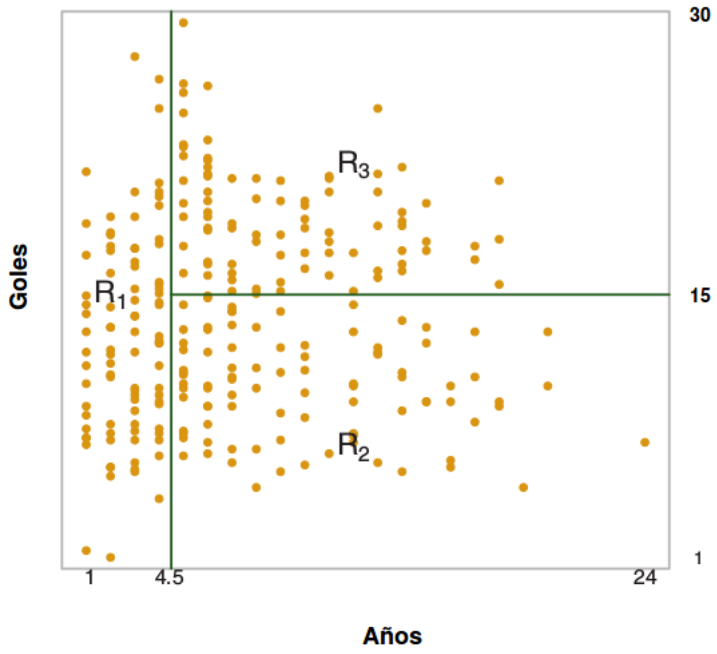


Figura 3.12: Regiones generadas por el árbol de decisión de la Figura

con poca experiencia, el número de *Goles* que realiza tiene poca incidencia en el salario, mientras que sucede lo contrario en aquellos con más años jugando.

- PREDICCIÓN POR ESTRATIFICACIÓN DEL ESPACIO DE CARACTERÍSTICAS
  Se discute el proceso de generación de un árbol de regresión. Básicamente, existen dos pasos:

  1. Se divide el conjunto de valores posibles para $X_1, \ldots, X_p$ en J regiones disjuntas no superpuestas, $R_1, \ldots, R_J$.
  2. Para cada observación que cae en una región R_j, hacemos la misma predicción, que es simplemente el promedio de los valores para todas las observaciones en R_j.

  Para construir las regiones $R_1, \ldots, R_J$ se divide el espacio de valores en *cajas* o rectángulos n-dimensionales. El objetivo es encontrar *cajas* $R_1, \ldots, R_J$ tales que minimizen la sumatoria RSS (*Residual sum of squares*), dada por

$$\sum_{j=1}^{J} \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2, \tag{3.15}$$

  donde $\hat{y}_{R_j}$ es el promedio de los valores de entrenamiento presentes en la región j-ésima. Desafortunadamente, es computacionalmente costoso considerar cada posible partición del espacio de caracteren J *cajas*. Por esta razón se toma un enfoque *top-down* y avaro, conocido como *división recursiva binaria*. Es *top-down* porque comienza en la raíz del árbol y corta el espacio de valores en ramas que continúan hacia abajo en el árbol.

Es *avaro* porque en cada paso se busca el corte que obtiene el mejor resultado para este paso particular.

Para aplicar *división recursiva binaria*, primero se selecciona la variable predictora X_j y el punto de corte s, tal que dividir el espacio de valores en las regiones $\{X|X_j < s\}$ y $\{X|X_j \geq s\}$ resulta en el menor valor posible para la ecuación de RSS. En más detalle, para cada j y s, se define el par de planos:

$$R_1(j,s) = \{X|X_j < s\} \; y \; R_2(j,s) = \{X|X_j \geq s\}, \tag{3.16}$$

y buscamos el vajor de j y s que minimizen la ecuación

$$\sum_{i:x_i \in R_1(j,s)} (y_i - \hat{y}_{R_1})^2 + \sum_{i:x_i \in R_2(j,s)} (y_i - \hat{y}_{R_2})^2, \tag{3.17}$$

donde $\hat{y}_{R_1}$ es el promedio de los resultados de las observaciones en $R_1(j,s)$ y $\hat{y}_{R_2}$ es el promedio de los resultados de las observaciones en $R_2(j,s)$. Luego, repetimos el proceso buscando el mejor predictor y el punto de corte para dividir los datos más aún buscando minimizar RSS dentro de las regiones resultantes. Sin embargo, en este caso, en vez de dividir todo el espacio de valores, solamente se divide una de las regiones previamente identificadas. El proceso continúa hasta que se cumpla cierto criterio, por ejemplo, hasta que ninguna región contenga más de cinco observaciones. Una vez obtenidas las regiones $R_1, \ldots, R_J$, se predice la respuesta usando el promedio de los valores de entrenamiento en la región correspondiente a la observación de test.

- ÁRBOLES DE CLASIFICACIÓN

  Un árbol de clasificación es muy similar a un árbol de regresión, solo que se utiliza para predecir una respuesta cualitativa. En vez de utilizar el promedio de valores de cada región, para un árbol de clasificación se predice que una observación pertenece a la clase con más ocurrencias de observaciones de entrenamiento en la región a la que pertenece. La tarea de generación de un árbol de clasificación es muy similar a un árbol de regresión. Se utiliza división recursiva binaria, pero no podemos utilizar RSS como criterio de corte. Una alternativa intuitiva es la tasa de error de clasificación, que es simplemente la fracción de datos de entrenamiento de la región que no pertenecen a la clase más común:

$$E = 1 - \max_k(\hat{p}_{mk}). \tag{3.18}$$

  $\hat{p}_{mk}$ representa la proporción de observaciones de entrenamiento de la región m-ésima que pertenecen a la clase k. Resulta que el error en la clasificación no es suficientemente sensible para generar un árbol, por lo que otras métricas son preferidas.

El *índice Gini* es una medida de la varianza total entre las K clases del conjunto y está definido como

$$G = \sum_{k=1}^{K} \hat{p}_{mk}(1 - \hat{p}_{mk}). \tag{3.19}$$

No es difícil ver que este índice toma un valor muy pequeño si todos los valores de $\hat{p}_{mk}$ son cercanos a 0 o 1. Por esta razón se considera a G como una medida de *pureza*: un valor pequeño indica que un nodo contiene observaciones predominantes a una sola clase.

Una alternativa al *índice Gini* es la *entropía cruzada*, dada por

$$D = -\sum_{k=1}^{K} \hat{p}_{mk} \log \hat{p}_{mk}. \tag{3.20}$$

Dado que $0 \leq \hat{p}_{mk} \leq 1$, se tiene que $0 \leq -\hat{p}_{mk} \log \hat{p}_{mk}$. Se puede mostrar que la *entropía cruzada* tomará un valor cercano a 0 si todos los valores para p_{mk} son cercanos a 0 o 1. Entonces, como sucede con el *índice Gini*, la entropía tomará valores pequeños si el m-ésimo nodo es puro.

Cuando se intenta generar un árbol de clasificación, cualquiera de las dos últimas métricas (ver expresiones 3.19 y 3.20) puede tomarse para evaluar la calidad de un corte, dado que estas medidas son más sensibles a la *pureza* de un nodo. En cambio, se elige el error de clasificación (definido en 3.18) si se busca mejorar la precisión en la predicción. Desafortunadamente, los árboles de decisión no tienen el mismo nivel de precisión que otros métodos de clasificación más complejos, como SVM. Sin embargo, agrupando varios árboles de decisión y unificando resultados se desarrollaron métodos como *Bagging* y *Random Forest*, mejorando significativamente el desempeño en la predicción.

3.2.3. Random Forest

En *Machine Learning*, un método de unificación es una técnica que combina las predicciones de múltiples algoritmos de aprendizaje para realizar predicciones más precisas comparadas contra un modelo individual. En esta sección veremos varios métodos de esta naturaleza que involucran árboles de decisión.

- BOOTSTRAP
  Bootstrap (o *Bootstrapping*) es una técnica estadística para estimar una métrica sobre un conjunto de datos. Como ejemplo introductorio, asumimos que tenemos una muestra

de 100 valores (X) y necesitamos estimar el promedio (esperanza) de la muestra. Podemos calcularlo directamente de la muestra como:

$$E(X) = 1/100 * suma(X) \tag{3.21}$$

donde $suma(X)$ es la suma total de los valores del conjunto. Sabemos del ejemplo dado que la muestra es pequeña y nuestro promedio obtenido con $E(X)$ tendrá cierto error al generalizar nuestro modelo. Podemos mejorar esto utilizando el procedimiento denominado *Bootstraping* que consiste en:

- Crear m sub-muestras aleatorias X_i del conjunto original con reemplazo (esto es, se pueden seleccionar valores repetidos).
- Calcular la esperanza $E(X_i)$ para cada sub-muestra.
- Calcular el promedio de cada valor obtenido en el paso anterior y utilizar este resultado.

Este proceso puede ser utilizado para estimar otras medidas descriptivas de un modelo como la varianza.

- BAGGING

  Bagging (***B**ootstrap **Agg**regat**ing***) es un método de unificación donde se generan m particiones de tamaño n con elementos tomados del *dataset* de entrenamiento usando selección aleatoria con o sin reemplazo (*Bootstrap*). Cada partición es usada para construir un nuevo modelo estadístico: en total se obtienen m modelos diferentes, que luego se unifican para formar uno solo. Más formalmente, se entrena el modelo en el b-ésimo conjunto de entrenamiento para obtener $\hat{f}^{*b}(x)$. Para realizar una predicción sobre $\hat{f}_{bag}$, estos modelos son encuestados y sus resultados son promediados.

$$\hat{f}_{bag}(x) = \frac{1}{m}\sum_{b=1}^{m} \hat{f}^{*b}(x). \tag{3.22}$$

  Una de las ventajas que se obtiene de esta técnica es una reducción en la varianza y por lo tanto, es utilizada en métodos de aprendizaje de alta variabilidad, como los árboles de decisión.

- IMPORTANCIA DE LAS VARIABLES PREDICTORAS

  Aunque una colección de árboles obtenidos por *Bagging* es más difícil de interpretar que un árbol de decisión individual, se puede obtener la suma total de la importancia de cada predictor utilizando RSS (para árboles de regresión) o el *índice Gini* (para árboles de clasificación).

- RANDOM FOREST

  Uno de los algoritmos de aprendizaje más potentes que utiliza *Bagging* es *Random Forest* [10]. En *Random Forest*, se entrena un número de árboles de decisión cada uno basado en diferentes muestras tomadas del *dataset* de entrenamiento utilizando *Bagging*. Pero cuando se crean estos árboles de decisión, cada vez que un corte es considerado, una muestra aleatoria de m predictores es elegida como candidatos a variables de corte tomados del conjunto total de p predictores. Se puede elegir solo una variable de las m para realizar el corte, y generalmente, se toma $m \approx \sqrt{p}$ (esto es, el número de predictores que se consideran para cada corte es aproximadamente igual a la raíz cuadrada del número total de predictores). En otras palabras, cuando se construye un modelo para *Random Forest*, el algoritmo no tiene disponible la mayoría de los predictores del conjunto de entrenamiento. Supongamos que en el *dataset*, existe una variable predictora muy fuerte, además de un número de otros predictores moderadamente importantes. En la colección de árboles de decisión generados por *Bagging*, la gran mayoría o incluso todos los árboles usarían la variable de mayor importancia como corte en el nodo raíz. En consecuencia, los árboles resultarían muy parecidos y las predicciones resultarían muy correlacionadas y en particular, no ayudaría a reducir la variancia.

  Random Forest resuelve este problema forzando a cada corte a considerar un subconjunto más pequeño de la cantidad total de predictores. Por lo tanto, en promedio, $(p-m)/p$ de los cortes ni siquiera considerarían el predictor más importante, haciendo que las otras variables predictoras tengan la oportunidad de demostrar su importancia en el modelo. Este proceso puede pensarse como *decorrelacionar* los árboles, logrando que el promedio de las predicciones de los árboles de decisión sea menos variable y más confiables.

  La diferencia principal entre *Random Forest* y *Bagging* es el tamaño del conjunto de variables predictoras en el corte m. Por ejemplo, si un modelo *Random Forest* es entrenado considerando $m = p$, sería equivalente a utilizar *Bagging*.

Capítulo 4

Extracción de características

Una vez realizada la normalización del dataset de imágenes de tomografías provistas por el HECA, se procede a la extracción de los *features* que nos servirán como entrada para el entrenamiento del clasificador estadístico. Estas características son la *línea media ideal* (iML) y la *línea media deformada* (dML), para luego extraer el valor de la *desviación de la línea media* (MLS), conceptos que fueron explicados previamente en la Sección 2.12.

4.1. Materiales

La base de datos posee 92 casos de imágenes TC de pacientes con traumatismo craneoencefálico, previamente registrados utilizando la herramienta ANTs [1]. El template (plantilla, concepto explicado en la Sección 1.2.3) para registrar los casos fue creada a partir de 29 pacientes normales, obteniendo la imagen TC de la Figura 4.1. Para apreciar un ejemplo claro de registración, se puede observar la Figura 4.2, donde se utiliza la plantilla de la Figura 4.1 para registrar el caso observado a la izquierda de la Figura 4.2.

Es de gran ventaja tener las imágenes registradas ya que, junto con la opinión de un experto en medicina, podemos asumir donde se encontrarán ciertas partes anatómicas útiles. En nuestro caso, las recomendaciones dadas por el médico fueron analizar las TC a 95 voxeles del plano axial para maximizar la presencia de todos los marcadores anatómicos. Es por ello que para nuestro análisis en 2-D de una TC, tomamos siempre el valor de $z = 95$.

Los programas (scripts) fueron codificados utilizando *Python 3.6.1*, las librerías *NiBabel* para leer archivos NIFTI, *NumPy* para análisis numérico y manipulación de matrices y *scikit-learn* para machine learning.

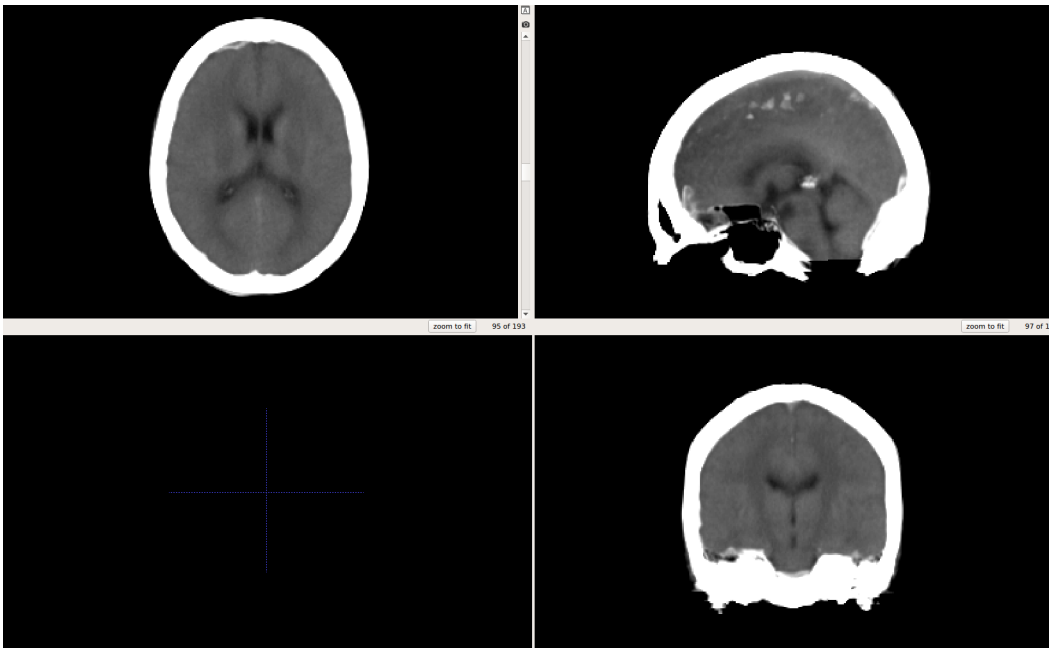


Figura 4.1: Arriba a la izquierda se observa el plano axial de la plantilla ($z = 95$). Arriba a la derecha el plano sagital ($x = 115$), y abajo la derecha el plano coronal ($y = 97$).

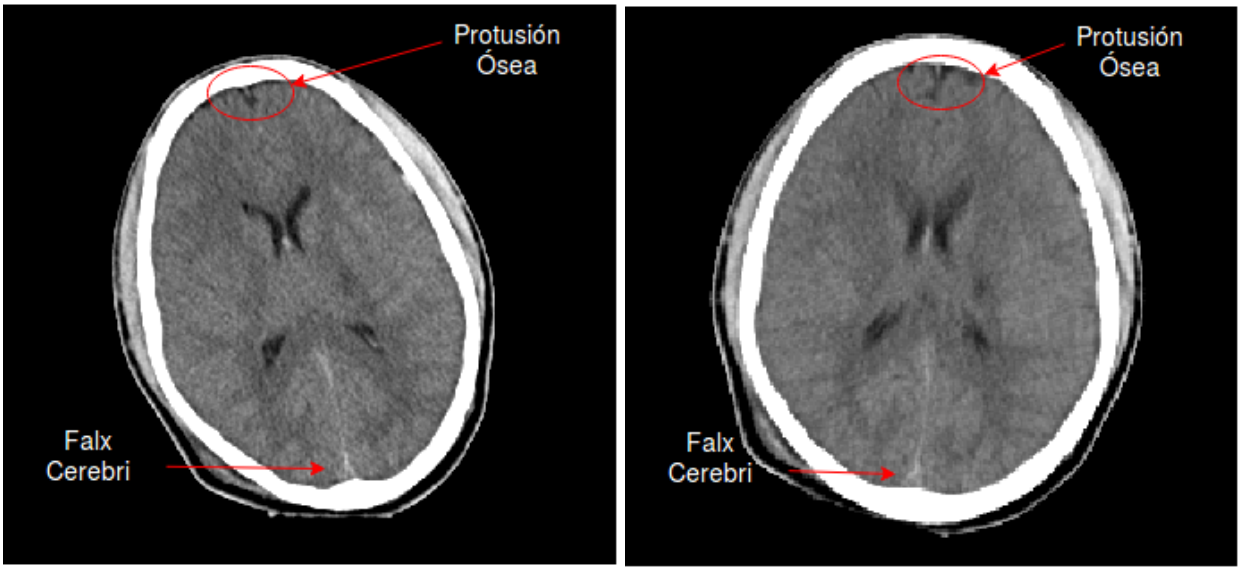


Figura 4.2: A la izquierda se observa la vista axial de una TC sin registración. A la derecha, la misma TC pero registrada utilizando nuestra plantilla. Se destacan en rojo las zonas del *falx cerebri* y la protusión ósea anterior.

4.2. Extracción de la línea media ideal

La detección de la línea media ideal, i.e., la línea media que debe estar presente en un cerebro sano, sirve como referencia anatómica para determinar la desviación total en el tejido cerebral. La línea media ideal puede ser aproximada usando la simetría axial del cerebro para los casos normales, sin embargo para casos con trauma es más robusto emplear otros marcadores tales como las protuberancias anterior y posterior del cráneo a y las fisuras inter hemisféricas [4].

4.2.1. Método

El método utilizado en este trabajo utiliza la protrusión ósea en la parte superior del cráneo y el pliegue del *falx cerebri* en la parte inferior para aproximar la línea de la iML, dado que estas características permanecen prácticamente intactas luego de un traumatismo [4, 6, 7]. Aunque podemos aproximar la iML usando simetría, se deben tener en cuenta estas características para tener una mejor precisión. El algoritmo de detección de la iML consiste de tres pasos concretos:

1. Detección de la protuberancia ósea en la parte anterior del cráneo.
2. Detección del pliegue del *falx cerebri* en la parte posterior del cráneo.
3. Aplicación del *algoritmo de Bresenham* [3] para el trazado de la línea media ideal.

Para los pasos 1 y 2 de la lista anterior, se exploran dos *bounding-box* (cajas envolventes) manualmente establecidas, como se muestran en la Figura 4.3. De ambas cajas envolventes, se obtienen dos pixeles: uno de la caja anterior y otro de la posterior. Luego de este paso se traza la iML con el algoritmo mencionado en el paso 3. Para detectar los pixeles de las protrusiones anterior y posterior, se aplica una umbralización ósea de acuerdo al valor correspondiente en la escala Hounsfield (ver Figura 2.5) y se obtienen las imágenes de la Figura 4.4. Luego se suman las intensidades de los pixeles que pertenecen a la parte ósea (ver Figuras 4.4) en el plano coronal, quedando para cada fila sagital la suma acumulada. El *offset* sagital que determinará la componente x del pixel en cada *bounding-box* se define como el argumento que maximiza dicha suma de intensidades. La componente y del pixel, se obtiene de la intersección coronal de la componente x y el hueso: para la caja anterior es el mínimo y la posterior el máximo. Una vez obtenidos los dos puntos correspondientes, la iML es trazada utilizando el algoritmo de Bresenham generando el resultado que se observa en la Figura 4.5.

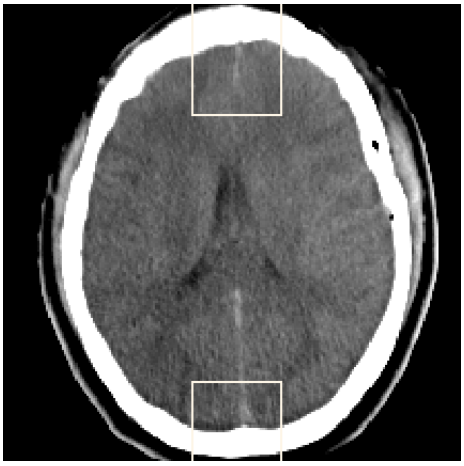


Figura 4.3: Imagen TAC remarcando las zonas anterior y posterior para la búsqueda de protuberancias.

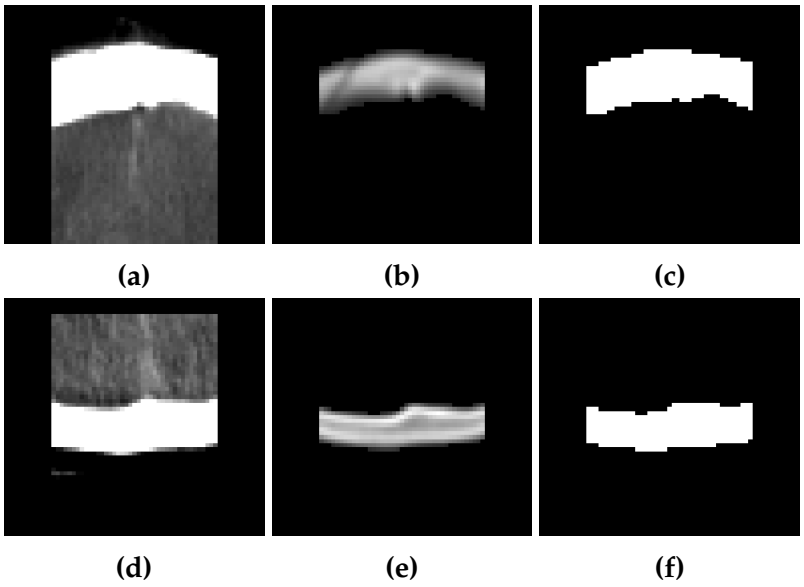


Figura 4.4: En (a) se observa la caja envolvente (plano sagital 2-D) de la posición anterior del cráneo. En (b) la misma zona aplicando un umbral de detección de hueso (UH $>$ 200). En (c), la misma imagen pero con cambio de valores en el contraste (nivel = 40 y ventana = 80). Las figuras (d), (e) y (f) muestran lo mismo para la *bounding-box* posterior respectivamente.

4.3. Extracción de la línea media deformada

La dML se define como la línea que, ya sea recta o curva, obtiene la mejor superposición de los puntos en un lado y sus contrapartes en el lado opuesto por simetría reflexiva [7]. Básicamente, representa a la línea media real en un cerebro con un TCE. El diagrama de flujo de nuestro algoritmo se describe en la Figura 4.6.

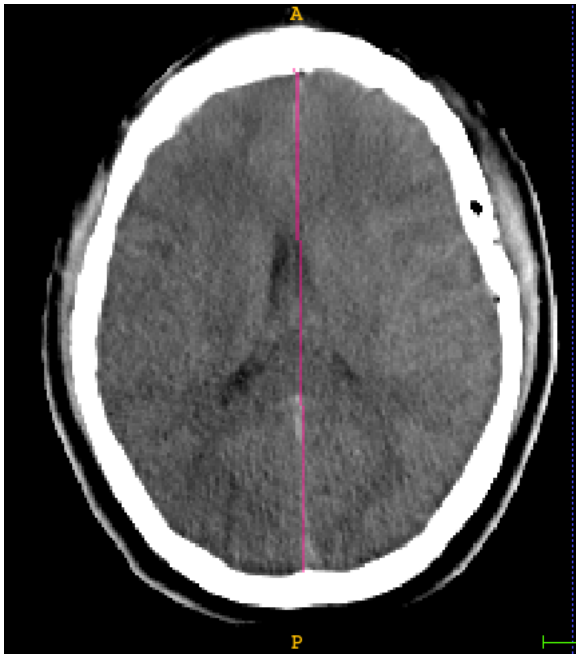


Figura 4.5: Ejemplo de iML empleando el algoritmo propuesto en la sección 4.2.

4.3.1. Generación del mapa de simetría

Se calcula el mapa de simetría de forma horizontal, dada la simetría bilateral del cerebro. Para cada punto (i, j) perteneciente al conjunto de pixeles de una imagen TC y dado n el número de pixeles a recorrer a cada lado del mismo, se define el mapa de simetría con la siguiente expresión:

$$S_{i,j} = \sum_{k=1}^{n-1} (I_{i+k,j} - I_{i-k,j})^2 (n-k)/n \tag{4.1}$$

donde $I_{i,j}$ denota la intensidad del pixel (i, j) en la imagen. En nuestro modelo, se prueban dos algoritmos diferentes de cálculo de la simetría: el primero, todos los pixeles tienen la misma importancia, i.e., el mismo peso, mientras que el segundo, los pixeles más cercanos al punto evaluado tienen más importancia. Se probaron varios valores de n obteniendo distintos resultados. Puede observarse un ejemplo de un mapa de simetría en la Figura 4.7.

4.3.2. El modelo paramétrico del algoritmo para la extracción de la dML

La idea principal de nuestro algoritmo es descomponer la dML en tres segmentos: la iML de la parte anterior y posterior (que pertenecen anatómicamente a la *hoz del cerebro*) hasta la zona ventricular, y el segmento interior de la zona ventricular, cuya curvatura estará determinada por un punto que minimize cierta función de intesidad de simetría denominada

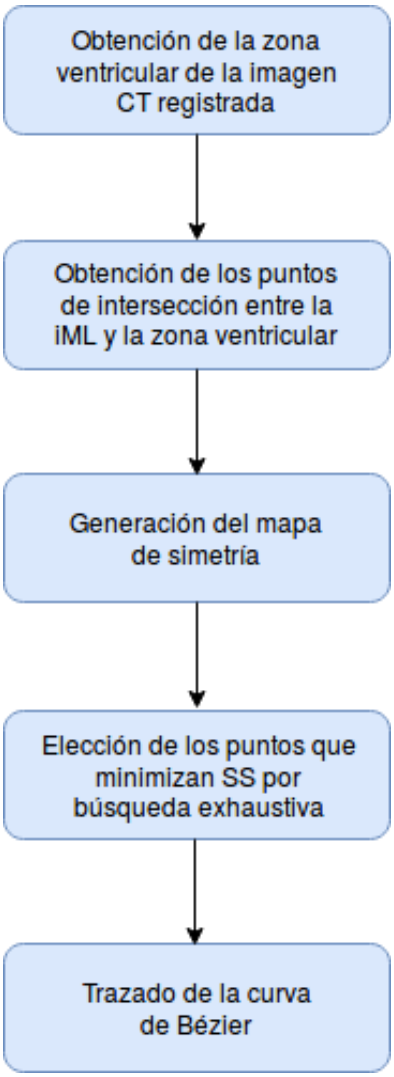


Figura 4.6: Algoritmo de extracción de la dML utilizado en el trabajo.

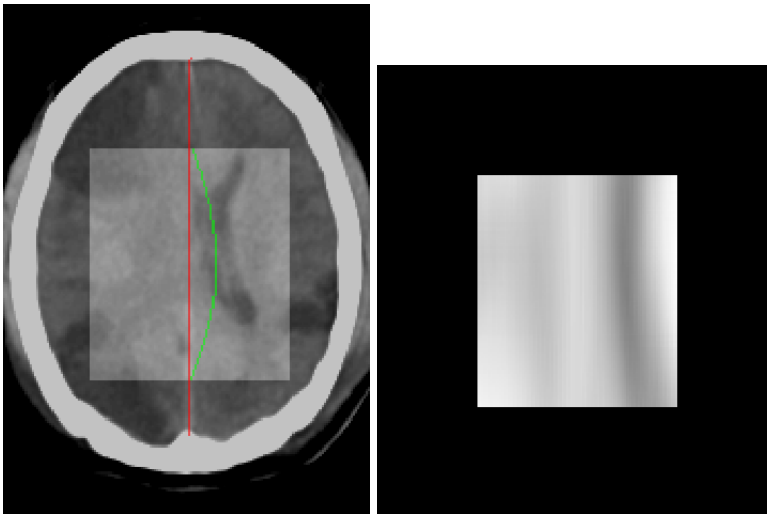


Figura 4.7: A la izquierda: una imagen TC con la iML en rojo y dML en verde, junto con la zona ventricular. A la derecha, el mapa de simetría de los pixeles de la zona ventricular. Note cómo las intensidades más cercanas a los ventrículos tienen menor simetría (pixeles más oscuros).

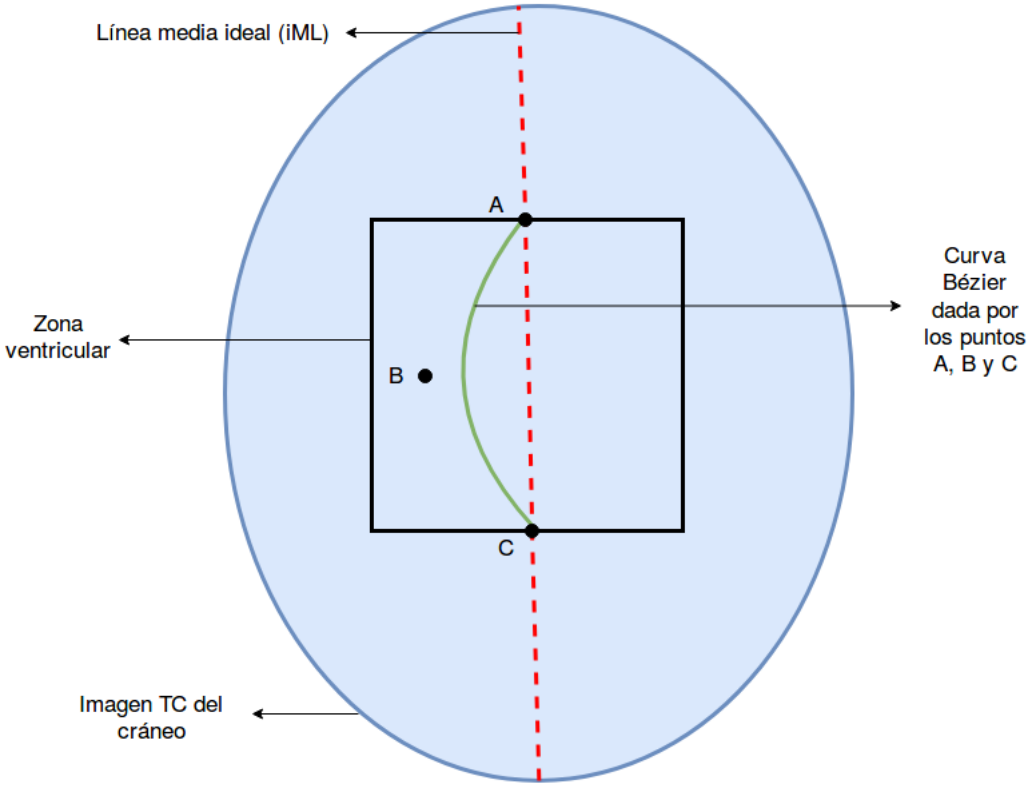


Figura 4.8: Los elementos del modelo de nuestro algoritmo representados sobre un cráneo en forma de óvalo. La línea punteada en color rojo es la iML (nótese que no necesariamente es exactamente perpendicular al cráneo). El rectángulo central es la zona ventricular. En verde, la línea que representa la curva de Bézier para los puntos A, B y C. B es el punto que minimiza la suma SS, mientras que las componentes del eje x para los puntos A y C quedan determinadas por la iML, y las componentes y por la zona ventricular.

SS que definiremos más adelante en esta sección. Este modelo puede apreciarse en la Figura 4.8.

Como primer paso en el flujo de la Figura 4.6, se observa la extracción de la zona ventricular. Se define esta zona como aquel conjunto de pixeles de la imagen de la TC que continene a los ventrículos. Se decide explorar sobre esta zona para acotar el espectro de búsqueda y reducir errores en el cálculo de simetría, a su vez teniendo presente que el test de referencia dado por el profesional médico no excediera, en el peor de los casos, los 20mm de distancia de la iML. Por lo tanto podemos tener la certeza que la dML detectada en esa zona va a resultar una buena aproximación.
El problema de detección de la línea deformada se reduce entonces a encontrar tres puntos en el plano 2-D, $A(x_A, y_A)$, $B(x_B, y_B)$ y $C(x_C, y_C)$, que determinen la curva de Bézier (ver Figura 4.9) que representa la dML bajo ciertas características que se explicarán a continuación. La idea principal de nuestro algoritmo es definir una función continua

$$\text{dML} : \mathbb{R} \to \mathbb{R} \tag{4.2}$$

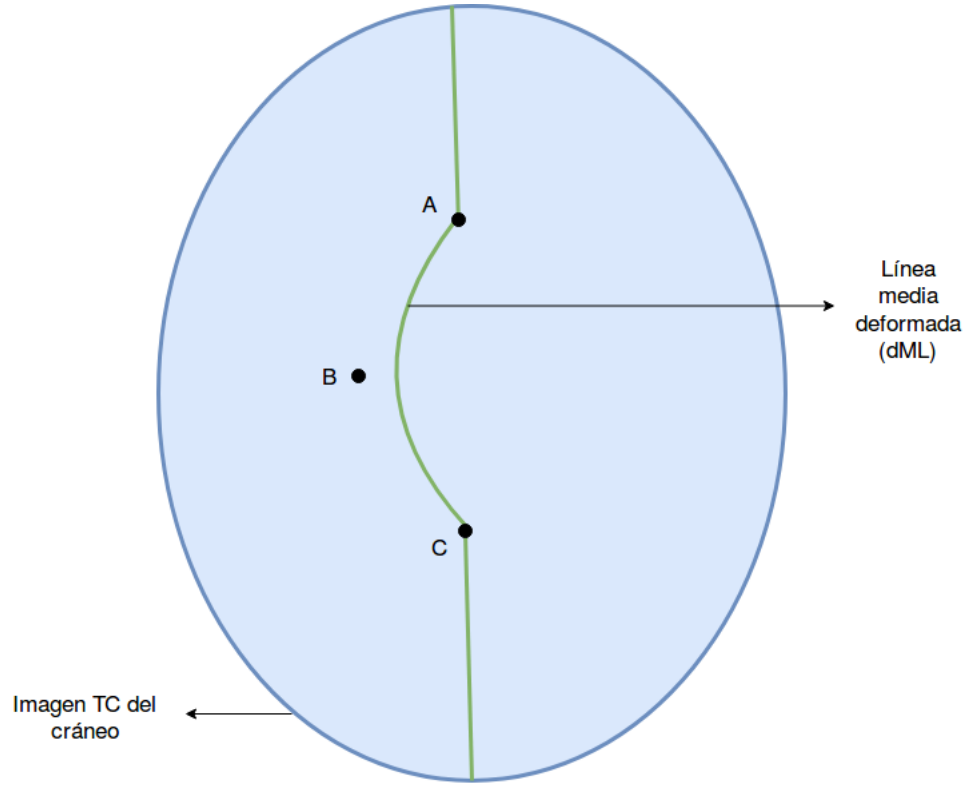


Figura 4.9: La línea media deformada determinada por nuestro algoritmo: para los segmentos posteriores y anteriores tomamos la iML; para el segmento del medio la curva Bézier.

que tome cierto valor en el eje y, y nos devuelva el punto x correspondiente a la línea media deformada. Si consideramos N puntos de control se define a la curva de Bézier como:

$$Z(t) = \sum_{k=0}^{N-1} p_k \frac{(N-1)!}{k!(N-k-1)!} t^k (1-t)^{N-k-1}, \quad 0 \leq t \leq 1 \tag{4.3}$$

siendo $Z(t)$ una función continua definida con N puntos de control discretos donde $t = 0$ en el primer punto y $t = 1$ en el último [15]. En nuestro caso particular se tiene $N = 3$ (Figura 4.8). La curva de Bézier, i.e., la función continua Z para nuestro problema queda entonces determinada por la siguiente ecuación:

$$Z(t) = A(1-t)^2 + 2Bt(1-t) + Ct^2. \quad 0 \leq t \leq 1 \tag{4.4}$$

Se asume que no se necesitan establecer los seis parámetros $(x_A, y_A, x_B, y_B, x_C, y_C)$ dado que x_A, y_A, x_C y y_C están determinados por la zona ventricular y la iML. Por lo tanto, el problema se reduce a encontrar dos parámetros (x_B, y_B). La ecuación 4.4 puede entonces refinarse aún más resultando en el sistema:

$$\begin{aligned} Z_x(t) &= A_x(1-t)^2 + 2B_x t(1-t) + C_x t^2 \\ Z_y(t) &= A_y(1-t)^2 + 2B_y t(1-t) + C_y t^2 \end{aligned} \tag{4.5}$$

4.3.3. Definición de la función dML como una función continua

Tanto la iML como la dML son curvas de puntos continuas. Supongamos definida la iML de la sección anterior como la función

$$\begin{aligned} &\text{iML} : \mathbb{R} \to \mathbb{R} \\ &\text{iML}(y) = x, \quad 0 \leq y \leq 228 \end{aligned} \tag{4.6}$$

y la dML como

$$\begin{aligned} &\text{dML} : \mathbb{R} \to \mathbb{R} \\ &\text{dML}(y) = \begin{cases} \text{iML(y)} & \text{si } 0 \leq y \leq y_A \\ Z_x(t) & \text{si } y_A \leq y \leq y_C \quad \text{con } y = Z_y(t) \\ \text{iML(y)} & \text{si } y_C \leq y \leq 228 \end{cases} \end{aligned} \tag{4.7}$$

Para poder parametrizar por completo la función dML en función de y, como se tiene que $y = Z_y(t)$, se computa la función inversa $Z_y^{-1}(y)$ utilizando el método de bisección hasta que el error de Z_y sea menor a la cota $0{,}5$ para obtener el valor de t correspondiente, dado que $\text{dML}(y) = Z_x(t) = Z_x(Z_y^{-1}(y))$ para $y_A \leq y \leq y_C$. Se redefine dML como

$$\begin{aligned} &\text{dML} : \mathbb{R} \to \mathbb{R} \\ &\text{dML}(y) = \begin{cases} \text{iML(y)} & \text{si } 0 \leq y \leq y_A \\ Z_x(t) & \text{si } y_A \leq y \leq y_C \quad \text{con } t = Z_y^{-1}(y) \\ \text{iML(y)} & \text{si } y_C \leq y \leq 228 \end{cases} \end{aligned} \tag{4.8}$$

La sumatoria de la métrica de simetría definida en 4.1 para cualquier línea media deformada determinada por los dos parámetros (x_B, y_B) queda entonces definida como

$$SS = SS(x_B, y_B) = \sum_{y=0}^{228} S_{\text{dML}(y),y} \tag{4.9}$$

y el problema se reduce a encontrar los valores para B, tales que minimicen SS. Nuestro método realiza una búsqueda exhaustiva pixel a pixel, calculando el mapa de simetría para toda la zona ventricular, y luego elige el punto B de menor intensidad para trazar la curva de Bézier y definir la línea media deformada.

4.3.4. Obtención de la zona ventricular

Por la zona ventricular circula el líquido cefalorraquídeo. El LCE tiene menor densidad en comparación con la materia gris y blanca del cerebro, lo que lo hace más oscuro en las tomografías. Nuestro objetivo entonces es diferenciar del tejido de la parénquima el LCE,

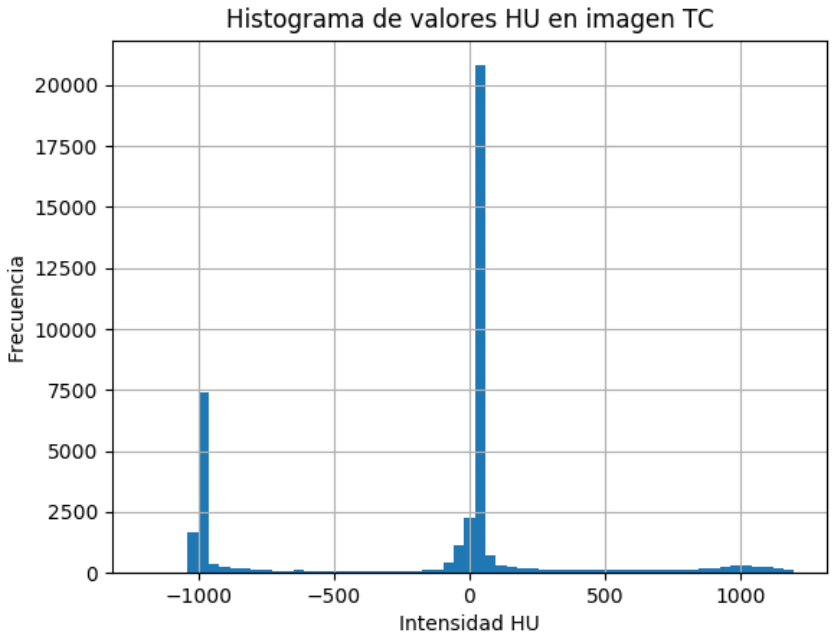


Figura 4.10: Histograma de valores UH en una imagen TC.

materia gris y materia blanca. Los valores típicos para el LCE son entre los 0 UH y 15 UH, entre 20 UH y 30 UH para la materia blanca y entre 37 UH y 45 UH para la materia gris (Figura 4.10). Este proceso se denomina clasificación de tejidos (tissue classification). En nuestro caso, debido a la simpleza, performance y efectividad, se utilizó el método no supervisado de clasificación k-means para realizar la separación, con las clases iniciales (intesidades UH) $0, 20, 25, 37$ y 45, debido a los valores típicos mencionados. Una vez realizada la caracterización de cada tejido, se forma la *bounding-box* que contiene a los ventrículos, como puede observarse en la Figura 4.11.

4.4. Cálculo de la desviación de la línea media

La desviación de la línea media es una de las características más importantes que los médicos utilizan para evaluar la gravedad del traumatismo craneoencefálico [7]. Se tienen los valores de la MLS anotados por el neurocirujano para los 92 casos y se compararán los resultados obtenidos con nuestro algoritmo. Se define a la MLS como la mayor distancia perpendicular entre la iML y dML, es decir

$$\text{MLS} = \max_{0 \leq y \leq 228} dist(\text{iML}(y), \text{dML}(y)) \tag{4.10}$$

puede observarse un esquema en la Figura 4.12.

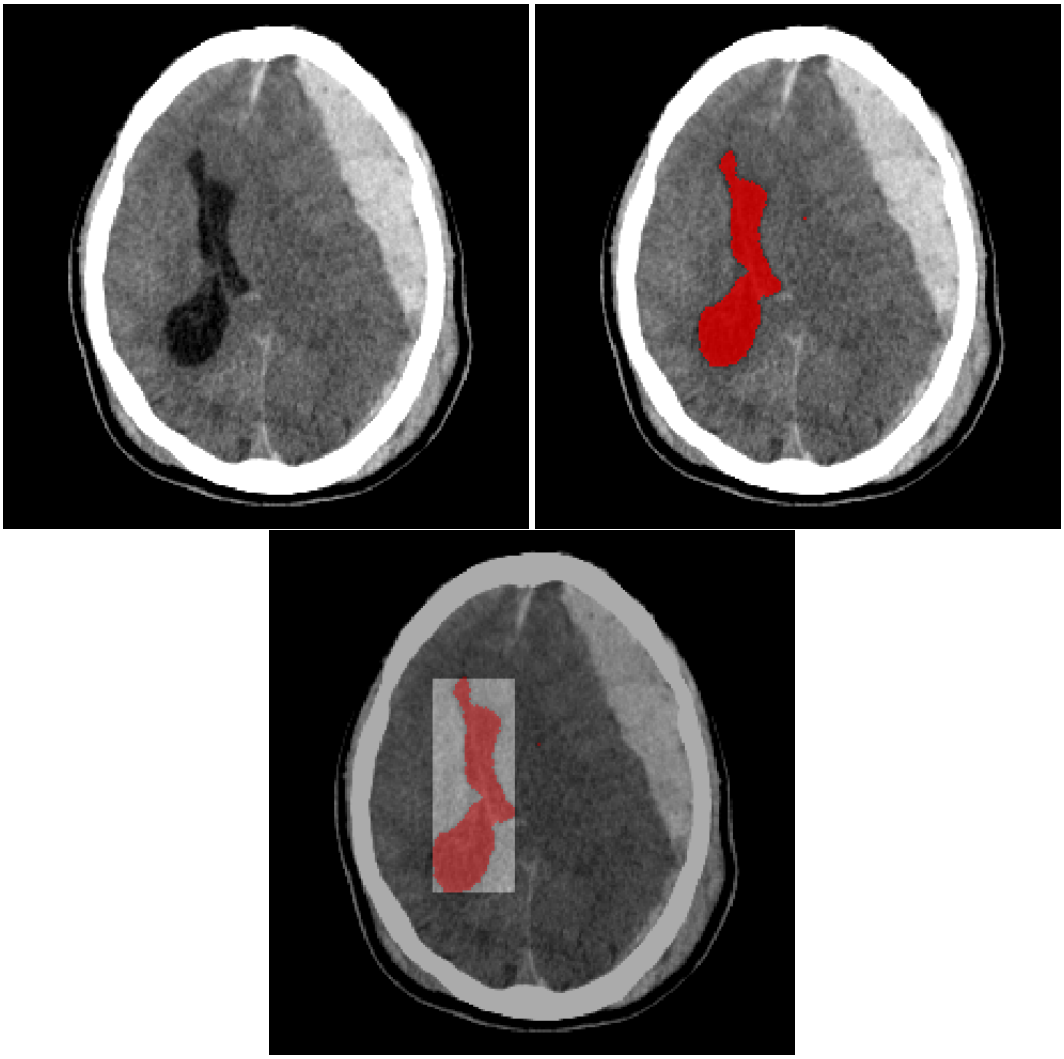


Figura 4.11: Arriba a la izquierda: el cráneo de un paciente. Pueden notarse los ventrículos bien marcados en un color más oscuro. Arriba a la derecha: los ventrículos detectados como segmentación. Abajo, la zona ventricular que se tomará en la búsqueda para este caso particular.

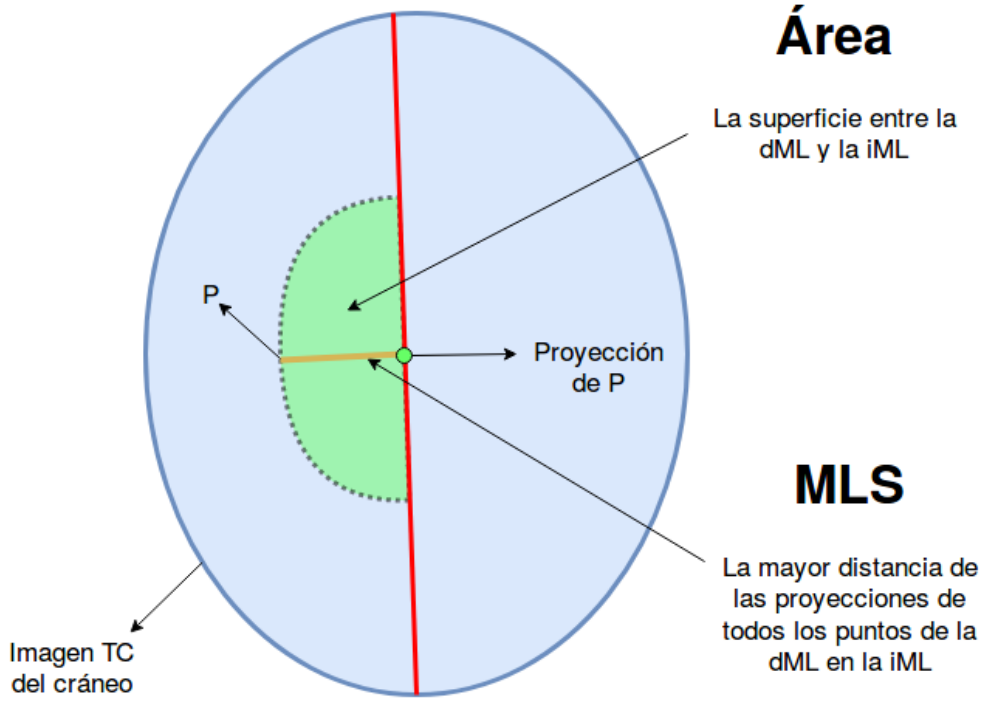


Figura 4.12: La línea punteada en verde es la dML y la línea roja la iML. El punto verde fluorescente es la proyección correspondiente del punto P en la iML, y la distancia entre ambos es una MLS candidata. La superficie en verde es el área entre la iML y la dML.

4.5. Cálculo del área entre la iML y dML

Otra de las características que nos resultó interesante extraer es el área entre las dos curvas. Los voxeles de nuestras imágenes TC son de $1mm^3$, por lo tanto el área de los píxeles es $1mm^2$. El área estará determinada por el número de pixeles entre la iML y dML, como puede observarse en la Figura 4.12. El algoritmo para obtener esta característica simplemente recorre pixel a pixel y suma las distancias absolutas entre las dos líneas. Este valor extraído se utilizará para la clasificación de traumatismos en el siguiente capítulo.

4.6. Resultados

Se utilizó el *dataset* de 92 casos mencionado al principio de esta sección, con el *gold standard* dado por el neurocirujano. El rango de edad es de 15 a 85 años, con un promedio de $34{,}8$ y una desviación estándar de $15{,}1$. De este conjunto, se extraen, dependiendo del rango axial y el *offset* utilizado en los parámetros de entrada del algoritmo, al menos 92 cortes axiales de la región que mejor contiene las características anatómicas interesantes, como los ventrículos. Esta altura axial (de 95 pixeles) fue dada por el neurocirujano. En base a otros trabajos en el área [4, 7, 6], nuestra base de datos es de un tamaño suficientemente grande para confiar en

los resultados obtenidos y compararlos con dichos estudios.

El cálculo de la desviación de la línea media se experimentó de acuerdo los siguientes parámetros:

- RANGO AXIAL
  Este argumento nota el número de cortes axiales de la imagen TC que se tienen en cuenta para calcular SS y realizar un promedio de los valores. Si el rango axial es 1, entonces se explorarán tres cortes axiales: a la altura usual $z = 95$, $z = 95 +$ *offset* y $z = 95 -$ *offset*.

- OFFSET DE SALTO
  El parámetro que determina los pixeles de distancia entre cada corte axial.

- RANGO HORIZONTAL
  Este parámetro especifica el número de pixeles a la izquierda y derecha de cada pixel al momento de calcular el mapa de simetría.

Como se mencionó en la sección de extracción de la dML, se implementaron dos algoritmos diferentes para el cálculo del mapa de simetría:

1. SIN PESOS
   Las intensidades de cada pixel a la izquierda y derecha del pixel actual tienen la misma importancia. Por lo tanto, el valor de simetría computado para cada pixel analizado k es $\sum_{k=1}^{n-1}(I_{i+k,j} - I_{i-k,j})^2(n-k)/n$

2. CON PESOS
   Las intensidades de cada pixel a la izquierda y derecha del pixel actual son proporcionales a la distancia al mismo. Es decir, si el pixel p_i se encuentra a k pixeles de distancia de p (actual), su intensidad real será de $\frac{1}{k}I(p_i)$ y la fórmula queda $\sum_{k=1}^{n-1}(\frac{1}{k}I_{i+k,j} - \frac{1}{k}I_{i-k,j})^2(n-k)/n$.

Lo que se compara en los resultados es la diferencia absoluta entre la MLS calculada por nuestro algoritmo y la correspondiente anotación encontrada por el profesional médico. El objetivo es determinar qué tan efectivo es nuestro algoritmo en comparación con la anotación de un experto. Los resultados obtenidos en los expermientos de acuerdo a las configuraciones de parámetros pueden observarse en el Cuadro 4.1.

Algoritmo	Rango axial (mm)	Offset (mm)	Rango horizontal (mm)	$\mu \pm \sigma$
Sin pesos	0	0	10	$3{,}1 \pm 2{,}95$
	1	3	10	$2{,}99 \pm 2{,}92$
	3	1	10	$2{,}90 \pm 3{,}02$
	0	0	20	$3{,}12 \pm 3{,}04$
	1	3	20	$3{,}01 \pm 2{,}92$
	3	1	20	$2{,}84 \pm 2{,}81$
	0	0	30	$2{,}83 \pm 2{,}75$
	1	3	30	$2{,}91 \pm 3{,}11$
	3	1	30	$2{,}79 \pm 2{,}77$
Con pesos	0	0	10	$3{,}04 \pm 3{,}17$
	1	3	10	$3{,}03 \pm 3{,}14$
	3	1	10	$3{,}01 \pm 3{,}11$
	0	0	20	$2{,}98 \pm 3{,}1$
	1	3	20	$3{,}12 \pm 2{,}89$
	3	1	20	$3{,}1 \pm 2{,}98$
	0	0	30	$3{,}1 \pm 2{,}99$
	1	3	30	$3{,}14 \pm 2{,}83$
	3	1	30	$3{,}17 \pm 2{,}96$

Cuadro 4.1: Resultados obtenidos (media μ y desviación estándar σ) para los valores de la diferencia (error) entre la MLS del test de referencia y nuestro algoritmo. Resaltado el algoritmo con menor media y desviación estándar del error.

		Valor real		
		MLS $>$ 5mm	MLS $\leq$ 5mm	Total
Predicción	MLS $>$ 5mm	12	0	12
	MLS $\leq$ 5mm	20	60	80
	Total	32	60	N

Sensibilidad	$37{,}50\,\%$
Especificidad	$100{,}00\,\%$
Exactitud	$78{,}26\,\%$

Cuadro 4.2: En el cuadro superior se observa la matriz de confusión del algoritmo sin pesos para la configuración de parámetros con mejor resultado del error del Cuadro 4.1. En este caso se comparan el *gold standard* y las obtenidas por nuestro algoritmo. El umbral de discriminación utilizado es que la MLS obtenida sea mayor a 5mm. En el cuadro inferior, se describen los valores de sensibilidad, especificidad y exactitud extraídas de la tabla de contigencia del cuadro superior.

Se definen como resultados *satisfactorios*, aquellos que tengan un valor de la diferencia en la MLS obtenida manualmente por el neurocirujano y automáticamente por nuestro algoritmo menor o igual a 5mm. Estos resultados fueron observados en 79 ($85{,}87\,\%$) imágenes. Los casos restantes, cuya diferencia fue mayor a 5mm, se consideraron resultados *no satisfactorios*, y se encontraron en 13 ($14{,}13\,\%$) imágenes. Ejemplos de casos donde el resultado observado fue

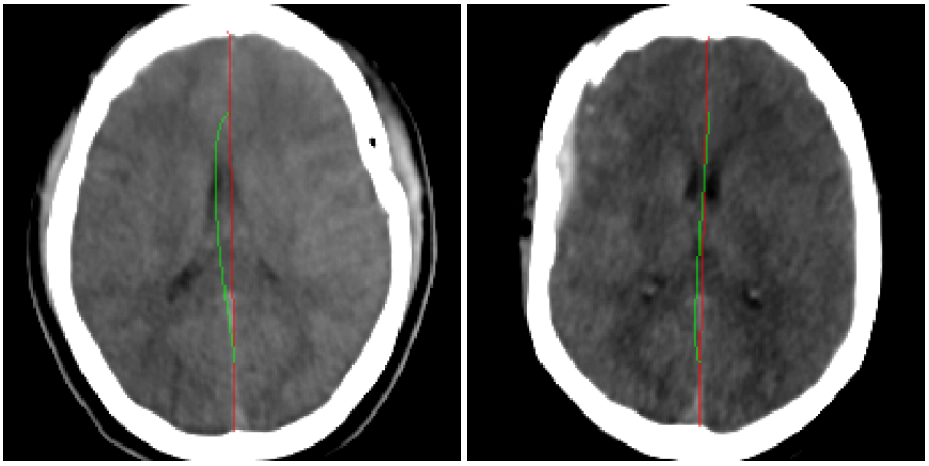


Figura 4.13: Se observan dos ejemplos donde el resultado fue considerado satisfactorio. La iML dibujada en rojo y la dML en verde. La diferencia entre la MLS obtenida manualmente y la automática es menor a 5mm.

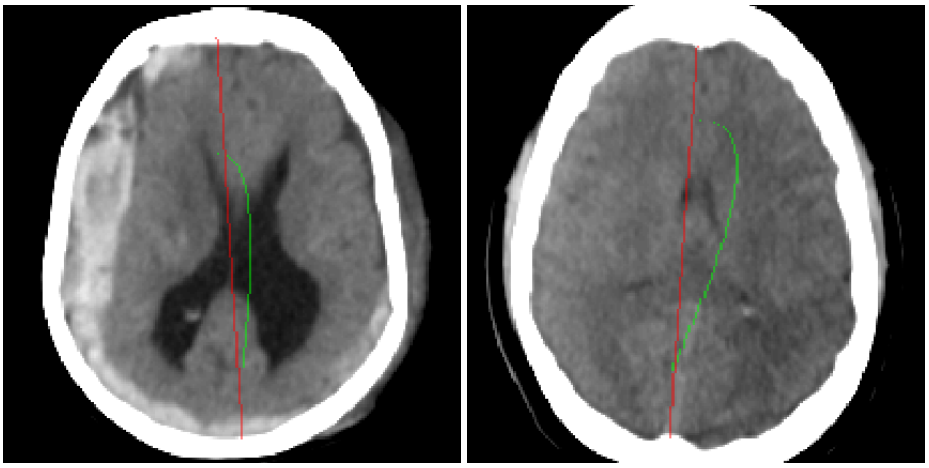


Figura 4.14: En esta figura se explicitan dos ejemplos donde el resultado fue considerado no satisfactorio. La iML dibujada en rojo y la dML en verde. La diferencia entre la MLS obtenida manualmente y la automática es mayor a 5mm.

satisfactorio puede verse en la Figura 4.13, mientras que los casos *no satisfactorios*, en la Figura 4.14.

4.6.1. Sensibilidad y especificidad

Desde el punto de vista clínico es de gran importancia saber cuándo la MLS supera los 5mm. Una persona sana tiene desviación de 0mm, mientras que una persona que sufrió un TCE, y tiene una MLS superior a 5mm puede ser diagnosticada con un trauma severo. Este estudio mide la eficacia del algoritmo estimando los valores de sensibilidad y especificidad contra las anotaciones del neurocirujano tomando como regla de decisión si la MLS supera los 5mm. El Cuadro 4.2 describe la matriz de confusión para la configuración de corrida del algoritmo resaltado en el Cuadro 4.1 sobre un *test* de medida de MLS con umbral de deci-

sión de 5mm. De esta prueba, se extrae información relevante a métricas de especificidad y sensibilidad que se exponen en el Cuadro 4.2. Los valores expuestos no son contra la diferencia anotada manualmente sino la MLS detectada por el algoritmo. Se consideran valores positivos aquellos con MLS > 5mm, mientras que negativos con MLS ≤ 5mm.

4.7. Discusión

La línea media, desviada o no, es una característica global que requiere una cantidad considerable de datos para ser computada [7]. Este capítulo presenta un algoritmo de detección de línea media automático aplicable a un número significativo de imágenes TAC reales. El método es bastante simple. Solamente requiere de un volumen TAC (si se busca promediar con cortes axiales), o bien, un corte axial para computar la dML. Es lo suficientemente robusto como para detectar la misma línea dML en cortes a distinta altura en el plano axial.
Los resultados generales fueron buenos. El promedio de error entre la MLS detectada por nuestro algoritmo y el *gold standard* manual dado por el neurocirujano es de $2{,}79$mm en la mejor configuración, con una desviación estándar de $2{,}77$mm (Cuadro 4.1). Para los casos donde el error fue mayor al umbral propuesto (Figura 4.14), es debido a que el mapa de simetría extraído no aporta datos certeros que son necesarios para nuestro algoritmo, o que los ventrículos no están lo suficientemente visibles para su detección. Esto puede ser consecuencia directa de la edad del paciente, los ventrículos aumentan en volumen a razón de 10ml por década hasta los 70 años aproximadamente para luego incrementar de manera exponencial. El único preprocesamiento que se aplicó a las imágenes que sirvieron de entrada del algoritmo, además de la registración, fue un *suavizado gaussiano*. La detección de otras características como sangre y presencia de hematomas, podrían ayudar a mejorar la precisión de la traza de la dML. La clasificación de pixeles, como se sugiere en [8], podría ser otra opción a considerar para mejorar la performance del algoritmo. Aunque el estudio realizado en este trabajo se realizó en cortes axiales 2-D, sería de gran interés el trazado de curvas en 3-D que grafiquen la deformación del plano ideal.

Los resultados de sensibilidad y especificidad obtenidos en la sección 4.6.1 sientan la base del desempeño actual del algoritmo desarrollado. De los resultados arrojados se puede destacar que nuestro algoritmo es $100\,\%$ específico: los casos negativos (desviación menor a $5mm$) son correctamente identificados en su totalidad. Esta propiedad es muy buena ya que los dichos casos son clasificados como tales por nuestro algoritmo. Por otro lado, es muy poco sensible ($37{,}50\,\%$), lo que nos dice que el porcentaje de pacientes con desviación mayor o igual a $5mm$ que son correctamente identificados con esa condición es bajo. Por ejemplo, se dan casos donde la desviación es alta y nuestro algoritmo lo caracteriza como baja. Esto podría resultar inconveniente si en la situación hipotética donde la línea media fuera un indicador suficiente de la gravedad del trauma del paciente y los médicos confiaran ciegamente en el

software, se podrían generar diagnósticos erróneos. Por lo tanto, las mejoras que se realicen al algoritmo deben intentar perfeccionar los valores de sensibilidad, especificidad y exactitud, es decir, acercar los tres valores al $100\,\%$.

Capítulo 5

Experimentos

En este capítulo se describirán y analizarán los resultados obtenidos en los experimentos realizados sobre el *dataset* de pacientes junto con las características extraídas de las imágenes TC en el capítulo anterior. El objetivo principal de este experimento es utilizar *Machine Learning* para medir el desempeño de las características extraídas por los algoritmos desarrollados en la predicción de la gravedad del trauma en pacientes con TCE en contraste con las mediciones manuales dadas por un especialista.

5.1. Base de datos

La base de datos utilizada fue provista por el HECA. Dicha base de datos contiene un total de 92 pacientes (79 hombres y 13 mujeres) con algún tipo de traumatismo clasificado en leve (L), moderado (M) y grave (G). De todos ellos, 32 pacientes presentan un grado de traumatismo leve ($35\,\%$), 23 moderado ($25\,\%$) y 37 grave ($40\,\%$). La media de la edad ronda los 34 años con una desviación de 15. En la Figura 5.3 se muestran 10 ejemplos de entradas de la base de datos de pacientes obtenidas. Puede observarse una descripción de los campos del dataset en el Cuadro 5.1.

5.1.1. Variables obtenidas en forma automática

En el capítulo 4 de este trabajo, se explica un algorítmo sistemático para obtener de imágenes TC las variables MLS_mm y $Area_mm^2$. Las restantes variables del Cuadro 5.1 cuya procedencia es automática (A), se obtuvieron como resultado del análisis del estudio de compresión de cisternas basales (ver Figura 5.1) realizado en un trabajo previo por el *Dr. Rafael Namías*. El objetivo principal de este trabajo es medir la proporción del líquido cefalorraquídeo en comparación con el tejido que lo rodea, obteniendo los valores correspondientes a los índices de compresión del *middlebrain*, *pons* y *médula oblongata*. Resulta interesante estudiar el nivel de LCR ya que, de acuerdo con la hipótesis (ver Sección 2.10) puede revelar

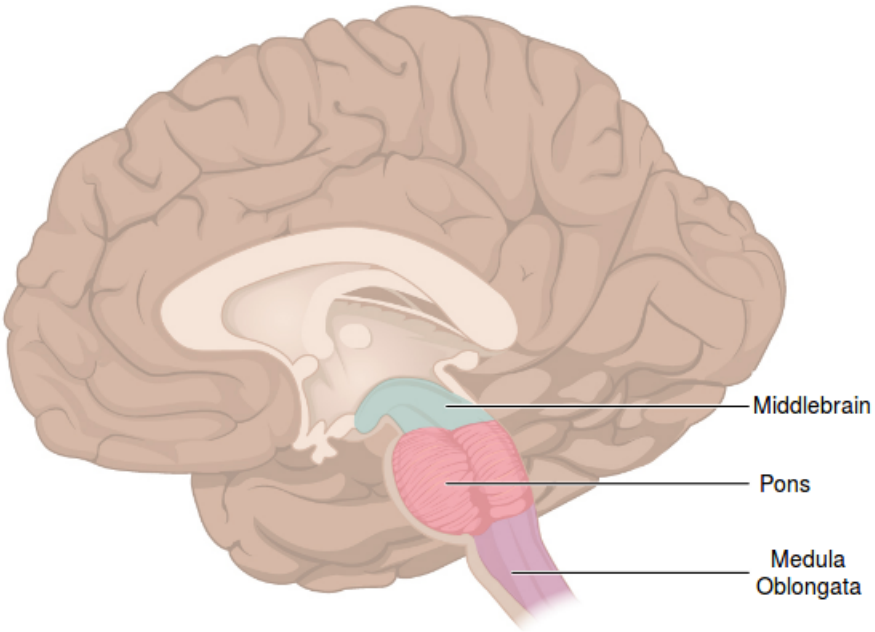


Figura 5.1: Las tres partes diferentes de la zona de cisternas basales coloreadas en una vista sagital del cerebro.

un elevado nivel de presión intracraneal y otros factores importantes que potencialmente determinen la severidad del traumatismo.

El método consiste en aplicar una máscara para seleccionar la región de interés que engloba las cisternas basales, comprendidas por la *médula oblongata*, el *pons* y el *middlebrain*. La Figura 5.2 muestra la máscara con las zonas anatómicas de interés superpuestas sobre el *template* de registración. Luego se separa el tejido por umbralización de intensidades de vóxeles (0UH para LCR, 25UH para materia gris y 35UH para materia blanca) y *k-means* como técnica de *clustering* para representar los diferentes tipos de tejido: LCR, materia gris y materia blanca. Finalmente se obtiene la tasa de compresión (los valores mostrados en el Cuadro 5.1) dividiendo el número de vóxeles de líquido cefalorraquídeo y la suma de vóxeles de materia gris y blanca.

5.2. Entrenamiento

Los métodos de entrenamiento utilizados fueron Árboles Aleatorios (*Random Forest*) y Máquinas de Vectores de Soporte (*Support Vector Machines*). La validación se realizó usando *10-fold cross-validation* (ver Sección 3.1.6). El tamaño del conjunto de test utilizado fue del $30\,\%$ del total de datos, asegurando que posea una proporción cercana a la distribución de las etiquetas en el dataset total. La optimización de parámetros se llevó a cabo utilizando la búsqueda en una grilla de valores (*Grid Search*). Los experimentos fueron codificados en *Python 3.6.1*, utilizando la librería de machine learning *scikit-learn*.

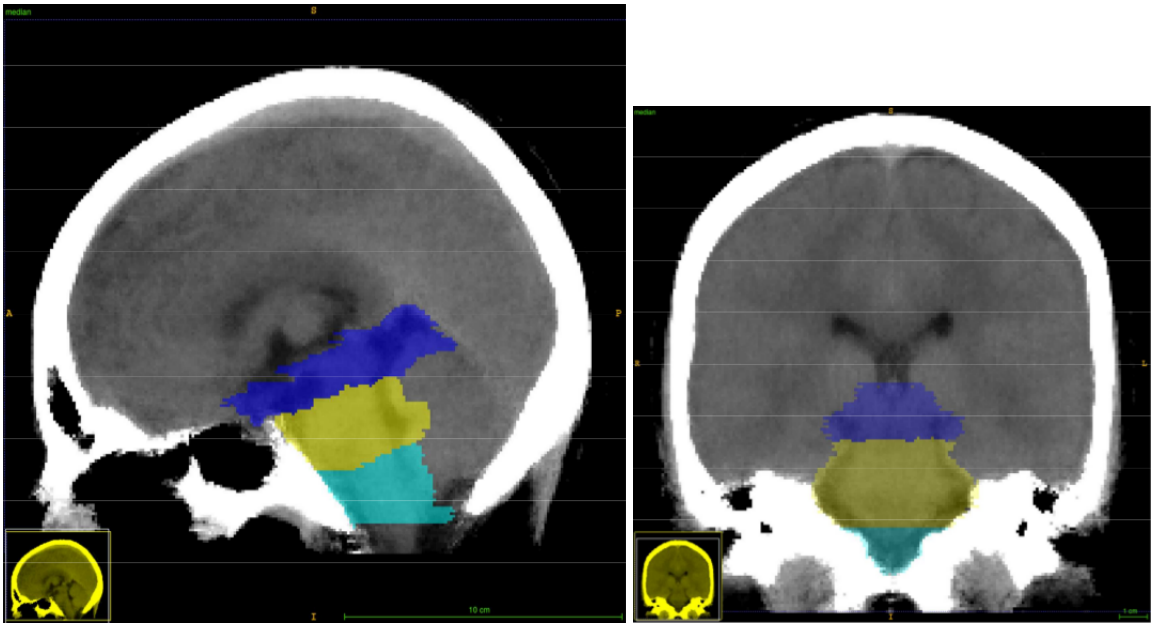


Figura 5.2: Vista coronal y sagital de una imagen TC junto con la segmentación de las tres regiones de las cisternas basales: el *middlebrain* en azul, el *pons* en amarillo y la *médula oblongata* desde la parte inferior del *pons* en color azul claro.

	Sexo	Edad	MiddleBrain	Pupils_Adm	GCS_Adm	Infecciones	PIC	Area_mm2	MLS_mm
43	1	39	0.29	2	14	1	0	34	1.38
31	1	29	0.08	1	3	2	0	669	14.60
59	1	27	0.12	1	15	1	0	150	3.55
85	1	59	0.20	1	13	0	1	352	6.47
19	1	51	0.32	1	15	1	0	73	2.36
50	1	25	0.16	1	15	1	0	186	4.50
65	2	22	0.08	1	8	1	0	252	4.58
1	1	47	0.14	1	7	1	1	345	7.41
23	1	19	0.05	1	3	2	0	299	3.72
16	1	36	0.10	1	15	1	0	127	2.00

Figura 5.3: Ejemplos de la base de datos de pacientes.

Variable	Procedencia	Significado
Sexo		Variable booleana (1 = Masculino, 2 = Femenino)
Edad		Edad de la persona
MiddleBrain	A	Índice de compresión del Middle Brain
Pons	A	Índice de compresión del Pons
Oblongata	A	Índice de compresión de la médula oblongata
Total_Cisterns	A	Índice de compresión de todas las cisternas
hMLS_mm	M	Desviación de la línea media en mm
hCompression	M	Índice de compresión de todas las cisternas
GCS_Adm		Glasgow Coma Scale en admisión
Pupils_Adm		Respuesta de dilatación de pupilas ante estímulo
Infecciones		Presencia de infecciones durante la internación
PIC		Presión intracraneal
Area_mm^2	A	Área entre la iML y dML en mm^2
MLS_mm	A	MLS en mm
Gravedad		Severidad del trauma anotada por el especialista (L, M o G)

Cuadro 5.1: Significado de cada parámetro del dataset. La procedencia indica si el valor de la variable fue obtenido por anotaciones manuales de un humano (M) o calculada automáticamente por un algoritmo (A).

5.3. Resultados

Como se describe al principio de esta sección, el objetivo de estos experimentos es analizar los datos y comparar la precisión en el diagnóstico de la gravedad de un trauma que se obtiene del estudio de las anotaciones de un especialista y los valores obtenidos automáticamente por computadora. Para lograr esto, se divide el dataset en dos partes semánticamente diferenciables: una con variables anotadas por especialistas y la restante generadas por los algoritmos. En el Cuadro 5.1 puede verse la procedencia de cada variable.

5.3.1. Predicción de la gravedad del trauma

En la Figura 5.4 se muestran los resultados obtenidos en los diferentes experimentos en términos de precisión, esto es, dada una fila de variables clínicas de un caso, intentar etiquetar la misma en un traumatismo L (leve), G (grave) o M (moderado). En todas las pruebas, las variables de procedencia M y A del Cuadro 5.1 son las que se seleccionan e intercambian: las restantes se mantienen intactas y se utilizan en todo momento.

A grandes rasgos, no se aprecia una diferencia remarcable entre los clasificadores utilizados, salvo en el primer análisis empleando todas las variables donde *SVM* obtiene los mejores resultados de todos los experimentos y *Random Forest* el más bajo. Esto es de esperarse para el segundo clasificador ya que varias variables empleadas se encuentra altamente correlacionadas, como *Total_Cisterns* y *hCompression* por ejemplo. En general y tomando ambos métodos

Resultados de la clasificación utilizando todas las variables del *dataset*					
Clasificador	L	M	G	Precisión	CV (+/- σ)
Random Forest	75,00	100,00	85,71	85,84	69,37 (+/- 34,01)
SVM	90,00	100,00	85,71	90,66	58,45 (+/- 38,09)

Resultados de la clasificación utilizando sólo variables anotadas por especialistas					
Clasificador	L	M	G	Precisión	CV (+/- σ)
Random Forest	81,82	100,00	92,31	90,86	76,44 (+/- 27,29)
SVM	72,73	75,00	85,71	92,31	76,94 (+/- 29,91)

Resultados de la clasificación utilizando sólo *MiddleBrain*, *Area_mm*^{2} *y MLS_mm*					
Clasificador	L	M	G	Precisión	CV (+/- σ)
Random Forest	81,82	100,00	85,71	88,03	74,94 (+/- 29,03)
SVM	72,73	75,00	92,31	82,04	71,69 (+/- 25,36)

Figura 5.4: En el cuadro superior, se observan los resultados con *todas* las variables del *dataset*: se incluyen tanto las variables anotadas por especialistas como los algoritmos. En el cuadro del medio se utilizaron solo variables anotadas por especialistas (del Cuadro 5.1, solo aquellas etiquetadas con M). En el cuadro inferior, se descartan todas las variables M del *dataset* y se tomaron del tipo A *MiddleBrain*, *Area_mm*^{2} *y MLS_mm*.

de clasificación, la precisión obtenida en la predicción de la gravedad de un caso es superior al $80\,\%$. También cabe destacar que en algunos casos, la validación cruzada expone cierto sobreajuste: se observa una mejora notable en los resultados de validación cruzada y varianza al remover parámetros (disminuír la dimensionalidad) tanto en *SVM* y *RF*. En términos generales, es un resultado aceptable dada la limitación en el número de casos disponibles (92) y la cantidad de variables utilizadas (entre 8 y 14).

5.3.2. Análisis y discusión del modelo propuesto

Uno de los aspectos que nos pareció interesante medir es la importancia de las variables obtenidas por computadora, ya que esto determinará si estas características extraídas automáticamente se corresponden con la importancia que conllevan las medidas por los expertos. Lo que se busca en esta ocasión es estudiar el desempeño de las variables obtenidas por algoritmos cuando actúan en reemplazo de las variables anotadas por médicos. Para esta sección se utilizó *Random Forest* únicamente ya que la implementación brinda como salida la importancia relativa de las características. En los cuadros 5.2 y 5.3 se representan los distintos subconjuntos del espacio de variables obtenidas por algoritmos y clínicas como subconjuntos de

$$A \cup C, \tag{5.1}$$

Predictor	$MPO_{Area,MLS}$	$TC_{Area,MLS}$	$MTC_{Area,MLS}$	$M_{Area,MLS}$
Sexo	0,023	0,031	0,028	0,029
Edad	0,087	0,109	0,1	0,019
MiddleBrain	0,093	-	0,101	0,108
Pons	0,084	-	-	-
Oblongata	0,093	-	-	-
Total_Cisterns	-	0,108	0,091	-
Pupils_Adm	0,006	0,008	0,008	0,008
GCS_Adm	0,365	0,429	0,394	0,426
Infecciones	0,031	0,04	0,035	0,046
PIC	0,03	0,031	0,03	0,037
Area_mm2	0,094	0,129	0,116	0,119
MLS_mm	0,093	0,116	0,097	0,118

Cuadro 5.2: Importancia de las variables utilizando *Random Forest* sin anotaciones por especialistas. En estos casos, se dejan ambas variables de análisis de la línea media obtenidas por computadora y se combinan las variables de compresión de cisternas basales.

donde $A = \{MiddleBrain, Pons, Oblongata, Total_Cisterns, Area_mm^2, MLS_mm\}$ y $C = \{Sexo, Edad, GCS_Adm, Infecciones, Pupils_Adm, PIC\}$. Se utilizaron para los nombres de los conjuntos de variables las iniciales de las variables algorítmicas y como subíndices si se usa el área o el desvío, e.g., $MPO_{Area,MLS}$ significa usar *MiddleBrain*, *Pons* y *Oblongata* con $Area_mm^2$ y MLS_mm.

En el Cuadro 5.3, se puede apreciar como los predictores *Area_mm2* y *MLS_mm*, en experimentos donde son excluídas mutuamente, tienen una importancia no despreciable, superior al $15\,\%$. Esto explicita que tienen una incidencia significativa en el resultado de la clasificación. Si constrastamos estos valores con los que se muestran en el Cuadro 5.4, se puede observar que la variable *hMLS_mm* tiene un porcentaje de importancia muy similar a los respectivos valores obtenidos por algoritmos (*MLS_mm* y *Area_mm2*). Esto es una buena señal para el objetivo de automatizar el proceso de diagnóstico, ya que al ser variables correlacionadas por conocimiento (las variables anotadas por médicos con las correspondientes por algoritmos), que muestren la misma incidencia en la predicción de casos determina que pueden brindar soporte al especialista. Sucede algo similar con las variables que miden compresión de tejidos: *hCompression* por el lado humano y *Total_Cisterns* y *MiddleBrain* por el lado automatizado. Aunque para el caso que mide variables obtenidas por especialistas (Cuadro 5.4) *hCompression* tiene una incidencia casi tres veces menor a sus correspondientes de algoritmos como *MiddleBrain* o *Total_Cisterns* (Cuadros 5.2 y 5.3), otras variables demuestran más importancia como la *edad* en este caso, con un porcentaje de $18\,\%$ (en los casos donde se usan variables de algoritmos, la edad tiene un porcentaje promedio al $14\,\%$). Se puede observar que estos resultados se relacionan bastante con las mediciones realizadas por computadora. La importancia de la característica *hCompression* es de casi la mitad de *Total_Cisterns*, como puede apreciarse en los subconjuntos $TC_{Area,MLS}$ y $MTC_{Area,MLS}$ del Cuadro 5.2 comparado con los resultados

Predictor	TC_{Area}	TC_{MLS}	M_{MLS}	M_{Area}
Sexo	0,036	0,034	0,035	0,034
Edad	0,132	0,142	0,141	0,138
MiddleBrain	-	-	0,138	0,151
Total_Cisterns	0,132	0,137	-	-
Pupils_Adm	0,014	0,014	0,013	0,013
GCS_Adm	0,437	0,408	0,427	0,41
Infecciones	0,051	0,058	0,052	0,058
PIC	0,041	0,041	0,044	0,045
Area_mm2	0,158	-	-	0,151
MLS_mm	-	0,166	0,15	-

Cuadro 5.3: Importancia de las variables utilizando *Random Forest* sin anotaciones por especialistas. Aquí se mide la importancia del índice de compresion del *MiddleBrain* contra el índice total (*Total_Cisterns*). Además, se utiliza solo una de las variables obtenidas por el algoritmo de extracción de la desviación de la dML.

Predictor	Importancia
Sexo	0,04
Edad	0,181
hMLS_mm	0,174
hCompression	0,048
Pupils_Adm	0,017
GCS_Adm	0,424
Infecciones	0,063
PIC	0,052

Cuadro 5.4: Importancia de las variables utilizando *Random Forest*, descartando los valores computados por algoritmos y dejando solo lo observado por especialistas.

en el Cuadro 5.4, y *hMLS_mm* tiene una importancia muy similar a *MLS_mm* y *Area_mm2* en prácticamente todos los subconjuntos de variables.

En líneas generales, desde una perspectiva médica y dado el tamaño de nuestro *dataset*, se obtuvieron resultados alentadores. Las características obtenidas por computadora resultaron ser de reelevancia similar a las mismas anotadas por especialistas, lo que demuestra que el algoritmo asemeja al comportamiento buscado por un especialista y puede servir como un indicador soporte para las decisiones de un médico de manera entendible y no como una caja negra.

Capítulo 6

Conclusiones

El principal objetivo de este trabajo final fue intentar objetivizar la medición de variables médicas mediante un método determinístico y comprobar que los resultados son similares a las mediciones establecidas por expertos. En particular, investigar desde el área de la computación, cómo brindar apoyo a las decisiones tomadas por un profesional de la medicina mediante un análisis objetivo y repetible. Se trató esta problemática desde dos campos diferentes pero estrechamente relacionados: el procesamiento de imágenes por computadora y el aprendizaje automatizado. El flujo de trabajo fue bastante bueno. Como primer paso, una base de datos de pacientes reales con TCE conteniendo las imágenes TC y variables clínicas fue provista por el HECA. Utilizando técnicas de manipulación de imágenes, se desarrollo un método sistemático de extracción de características relevantes al estudio (como la MLS) de las imágenes TC y se compararon los resultados obtenidos con el *gold standard* provisto por el neurocirujano. Por otra parte, se utilizaron las variables clínicas junto con las características extraídas para entrenar un modelo estadístico de aprendizaje que pueda predecir el nivel de gravedad del traumatismo clasificado en leve, moderado o grave.

En este trabajo se logró una implementación automática de extracción de características de imágenes tomográficas (dML y cálculo de MLS) eficiente, robusto y con resultados bastante aceptables desde el punto de vista médico.
En cuanto a la clasificación y predicción de la severidad del trauma, sabíamos de antemano que teníamos ciertas limitaciones dado el tamaño de nuestra base de datos, y si bien la precisión de los métodos no dio grandes resultados, se consiguió mostrar que las variables extraídas por nuestros algoritmos eran clave en la importancia de la predicción, lo que indica que el aporte es significativo y promete un panorama alentador para continuar con el estudio.

Como trabajo a futuro, uno de los objetivos a corto plazo es el de mejorar los resultados en la predicción de severidad del trauma. Con tal fin, consideramos ampliar el número de ejemplos mediante la colaboración estrecha con el HECA para poder validar y posiblemente general un modelo más eficaz. Una manera práctica de y simple de hacer esto es mediante

el uso de base de datos públicas como el *dataset* provisto por *Qure.ai*[1], que posee una gran cantidad de casos para el uso público con fines de investigación, el cual no se encontraba disponible al comienzo de este trabajo. Si se consigue mejorar el desempeño del clasificador y se logran resultados interesantes, se plantea enviar una publicación académica con las conclusiones obtenidas. Otro de los objetivos es desarrollar una aplicación web para automatizar el proceso de análisis de imágenes TAC, extracción de características y predicción, para brindarles a los especialistas del HECA una herramienta interactiva que sirva como soporte para el diagnóstico. En cuanto a procesamiento de imágenes, también podría ser interesante estudiar la extracción de otras características como detección de sangre y presencia de hematomas, tanto para contrastar lo obtenido con anotaciones por especialistas como para mejorar el método de detección de línea media.

[1] http://headctstudy.qure.ai/

Bibliografía

[1] ANTs, Advanced Normalization Tools.

[2] Harrison H. Barrett. Fundamentals of the radon transform. In Max A. Viergever and Andrew Todd-Pokropek, editors, *Mathematics and Computer Science in Medical Imaging*, pages 105–125, Berlin, Heidelberg, 1988. Springer Berlin Heidelberg.

[3] Jack E. Bresenham. Algorithm for computer control of a digital plotter. *IBM Systems Journal*, 4(1):25–30, 1965.

[4] Wenan Chen, Rebecca Smith, Soo-Yeon Ji, Kevin R. Ward, and Kayvan Najarian. Automated ventricular systems segmentation in brain ct images by combining low-level segmentation and high-level template matching. *BMC Medical Informatics and Decision Making*, 9(1):S4, Nov 2009.

[5] Mark Faul, Likang Xu, Marlena Wald, and Victor Coronado. *Traumatic Brain Injury in the United States: Emergency Department Visits, Hospitalizations and Deaths*. 03 2010.

[6] Saurabh Kumar Verma, Vijay Kumar Gupta, Tony joseph Rappai, Sanjeev Attry, Ekata Gupta, Nishtha Vashisth, and Saurabh Bhargav. Early indicators of prognosis in traumatic brain injury and their association with outcome. 16:44–48, 06 2017.

[7] Chun Chih Liao, Furen Xiao, Jau Min Wong, and I-Jen Chiang. A simple genetic algorithm for tracing the deformed midline on a single slice of brain ct using quadratic bézier curves. In *Proceedings - IEEE International Conference on Data Mining, ICDM*, pages 463–467, 2006.

[8] Sven Loncaric, Atam P. Dhawan, Dubravko Cosic, Domagoj Kovacevic, Joseph Broderick, and Thomas Brott. *Quantitative intracerebral brain hemorrhage analysis*, volume 3661, pages 886–894. Society of Photo-Optical Instrumentation Engineers, ii edition, 1999.

[9] Dearden M. Teasdale G.M. et al. Maas, A.I.R. *Acta neurochir*, page 139: 286, 1997.

[10] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, New York, 1997.

[11] National Institutes of Health. Ventricles of the brain. `https://medlineplus.gov/ency/imagepages/9567.htm`, 2011. [Online; Review Date 11/22/2017].

[12] A. Parent. *Carpenter's Human Neuroanatomy*. Williams & Wilkins, 1996.

[13] Real Academia Española. Definición de *aprender*.

[14] Vladimir N. Vapnik. *The Nature of Statistical Learning Theory*. Springer, 1995.

[15] Alan H. Watt and Mark Watt. *Advanced animation and rendering techniques: theory and practice.* New York, N.Y., 1992.