Propuesta de Tesina para la obtención del grado Licenciado en Ciencias de la Computación

16 de octubre de 2023

Postulante: Mariano José Crosetti

Director: Dante Zanarini

Codirector: Pablo Granitto

1. Situación del postulante

Al momento de presentar la propuesta, el estudiante debe defender el trabajo práctico final de Análisis de Lenguajes de Programación, poseyendo todas las otras materias rendidas y aprobadas. Quedando pendiente (luego de haber rendido ALP) los trámites pertinentes para subir al registro Siu Guaraní las materias: Análisis de Lenguajes de Programación, Compiladores, Taller de Tesina y Práctica Profesional.

Se espera dedicar al menos 20 horas semanales a la realización de la tesina.

2. Título

Desarrollo de módulo de validación automática de datos consignados en documentos electorales.

3. Motivación y Objetivo General

El actual proyecto de tesina se desarrolla en el marco del proyecto de incorporación de dispositivos tecnológicos que asistan el proceso electoral impulsado por el Gobierno de Santa Fe a través de la Secretaría de Tecnologías para la Gestión (STG). Particularmente del sistema de escrutinio provisorio con asistencia digital.

Actualmente el *Sistema de Escaneo y Transmisión de Telegramas* (SETT) y *Sistema de Asistencia a las Autoridades de Mesa* (SIAAM) proveen soluciones robustas de asistencia digital al proceso de escrutinio provisorio demostrando:

1. Aumentar el cubrimiento de mesas en el escrutinio provisional.
2. Disminuir el porcentaje de votos *"a determinar en el escrutinio definitivo"*.
3. Aumentar considerablemente la celeridad en la carga de telegramas.

4. Disminuir las solicitudes de reenvío de telegramas.

Trabajaremos en algunas propuestas de [7] (sección 7.3) desarrollando un módulo que mejore aún más los dos últimos puntos del apartado anterior atacando los errores más recurrentes según las estadísticas disponibles de uso de los sistemas en elecciones pasadas:

- Números ilegibles.[1]
- Requisitos formales no cumplidos (fundamentalmente presencia y coincidencia de firmas).

Para lo cual desarrollaremos un módulo adicionable al que se encarga del envío de telegramas que valide de forma automática y *advierta* a las autoridades del local de posibles errores[2]. Particularmente la idea es detectar:

1. Presencia de números en la grilla de contabilización de votos y consistencia de los mismos (por ejemplo verificación de totales).
2. Presencia de firmas y validación de coincidencia entre ellas (cuando una misma persona debe firmar más de una vez en diferentes hojas).

Para el último punto exploraremos el estado del arte del problema de *"Verificación Automática de Firmas Manuscritas"*. El problema que aquí se nos plantea es una variación en donde queremos determinar si dos firmas consignadas coinciden (son de la misma persona) sin poseer un registro anterior de firmas auténticas para los agentes. Creemos que nos permitirá investigar en un problema novedoso y desafiante de inteligencia artificial de envergadura y complejidad[3] para el cuál esperamos arrojar un poco de luz sobre lo ya conocido y proveer resultados aceptables a nivel de ser usados en una aplicación del mundo real.

El sistema deberá contar con la robustez para poder ser adaptado con menores cambios a las variantes en formatos y requisitos que puedan surgir en procesos electorales futuros. Además deberán analizarse que cumpla los requisitos de seguridad, disponibilidad, escalabilidad y auditabilidad requeridas en un proceso tan complejo y crítico cómo es el proceso electoral.[4]

4. Fundamentos y estado del conocimiento sobre el tema

Actualmente el software provisto en SETT y SIAAM para el envío de telegramas cuentan con módulos de validación que previenen, por ejemplo de enviar hojas en blanco. Se trabajará sobre la base de éstos software tratando de ser

[1] Si bien los números ilegibles son casi totalmente eliminados por SIAAM, nuestro sistema podrá funcionar en lugares que implementen SETT pero no SIAAM.

[2] El sistema *asistirá* a las autoridades advirtiendo de posibles errores, pero en ningún momento restringirá el derecho de las autoridades designadas de enviar los telegramas.

[3] Implicará confeccionar un dataset, formalización del problema, elección de métricas para medir la performance, desarrollar métodos robustos de validación de resultados.

[4] Si bien sólo nos centraremos en el proceso de escrutinio provisorio creemos que de por sí tiene éste consecuencias políticas y prácticas que lo transforman en un proceso crítico y un objetivo potencial de ataques por parte de terceros.

consistentes con las tecnologías empleadas adheriendo un módulo para la validación de los datos. Una detallada descripción del Proceso de Escrutinio Provisorio Asistido Digitalmente podemos encontrar en [5]. Para la verificación de consistencia con los datos registrados en códigos QR las especificaciones técnicas de los mismos se encuentra en [6].

Con respecto a la detección de dígitos (para la validación de los datos de conteo de votos) es conocido que el estado actual del arte logrado para éste problema posee niveles de precisión aún mejores que las capacidades humanas. Es menester, no obstante, indagar alguna solución de ingeniería que pueda ser incorporada al sistema y testear su adecuado funcionamiento (no sólo en precisión sino en velocidad, escalabilidad y demostrable auditabilidad) en un ambiente de producción simulada.

En relativo al problema de detección y coincidencia de firmas nos situaremos principalmente en [3] para obtener una perspectiva del estado del arte del problema y las opciones técnicas disponibles. Tomaremos para construir el estado del arte [2] y [1]. Consultaremos [4] para el proceso de extracción de firmas.

Los resultados de precisión actuales son prometedores para construir una implementación que funcione en producción. No obstante llegado el caso podríamos analizar nuestras propias variantes de solución, especialmente probando con representaciones generadas por redes convolucionales profundas (técnica que ha revolucionado el estado del arte de muchos problemas en los últimos años, especialmente de problemas ligados a computer vision [8]).

Podemos anticipar el desafío técnico de trasladar la solución a los dispositivos móviles que se ocupan de la transmisión de los telegramas sin degradar la escalabilidad y disponibilidad. Además la auditabilidad (característica que dado el ámbito de aplicación es fundamental) presentará su veta desafiante debido a la opacidad característica de los algoritmos de *machine learning* que se pretenden aplicar.

5. Objetivos específicos

1. Investigar soluciones al problema de detección, extracción y análisis de coincidencia de firmas manuscritas.
2. Extender el software para dispositivos móviles encargados de la transmisión de telegramas, incorporando:
   - Validación de la prescencia de números y consistencia de los mismos (entre ellos por ejemplo, verificando totales y respecto a los datos codificados en QR si los hay).
   - Validación de presencia de firmas y coincidencia entre ellas.
3. Crear un software para especificar, dada una plantilla con el formato del telegrama:
   - Las secciones de la hoja que deban contener firmas.
   - Las secciones de la hoja que deban contener números.
   - Relaciones entre los números extraídos (para expresar restricciones de consistencia entre los números).

- Relaciones de coincidencia entre las firmas extraídas (para expresar restricciones de consistencia entre las firmas).

El objetivo es que dichas zonas de la hoja no estén predefinidas en el código sino que puedan ser configurables por un usuario no programador por medio de un asistente. De modo que cuando el formato de los telegramas cambie (algo muy probable) se pueda adaptar el sistema facilmente.

6. Metodología y plan de trabajo

En términos generales se pretende destinar al menos 6 horas diarias a la realización de la tesina. Además se propone realizar comunicaciones periódicas semanales (reuniones 1:1) con el director (Dante Zanarini) explicando el progreso y orientando el trabajo.

Para alcanzar el primer objetivo se pretende hacer una implementación de los algoritmos descriptos en [3] y probarlos en un dataset conocido. Luego se intentará probar alguna técnica de redes profundas sobre el mismo conjunto de datos y problema. Finalmente construiremos nuestro dataset, formalizaremos nuestro problema particular (coincidencia de firmas) y trataremos de adaptar lazs soluciones a esta variación del problema.

Para los segundos y tercer puntos se pondrá a disposición del estudiante el software con el que ya se cuenta para el recortar y preprocesar los telegramas enviados. Se discutirá con los tutores qué extensiones realizar y se debatirán el cómo (la elección de tecnologías que permitan satisfacer las especificaciones de disponbilidad, escalabilidad y auditabilidad).

6.1. Programa tentativo de trabajo

- Redactar un estado del arte del problema de detección de firmas: **1 semana**.
- Elegir un dataset conocido para éste problema (para el cuál se conozca el estado del arte) y realizar una implementación propia de alguno de los algoritmos analizados (podría consultarse [3], [1] , [2]) y probarlos en algún dataset conocido: **1 semana**.
- Probar una solución alternativa utilizando redes profundas: **1 semana**.
- Crear nuestro dataset a partir de los telegramas disponibles y valiéndose del software de recorte y preprocesamiento ya disponible: **1 semana**.
- Explorar en el problema de extracción de firmas sobre el dataset construido (valiéndose de [4]): **1 semana**.
- Formalizar el problema de coincidencia de firmas. Probar en adaptar las soluciones al problema de Verificación Automática a este nuevo problema: **2 semanas**.
- Explorar soluciones aplicables para la detección de dígitos. Probarla en los conjuntos de datos de telegramas: **2 semanas**.

- Diseñar e implementar (teniendo en cuenta necesidades también no funcionales) el software que irá dentro de los dispositivos móviles: **4 semanas**.
- Diseñar e implementar el asistente para configurar un formato de telegrama: **1 semana**.
- Redacción del informe final: **4 semanas**. La propuesta es ir redactando a medida que se avanza con las demás fases siempre que sea posible.

Referencias

[1] G. Pirlo D. Impedovo y D. Barbuzzi. *Multi-classifier system configuration using genetic algorithms.* Proc. of International Conference on Frontiers in Handwriting Recognition (ICFHR). pages 560–564. 2012. ISBN: 38(5):609–635, 2008.

[2] D. Impedovo y G. Pirlo. *Automatic signature verification: The state of the art.* EEE Trans. on Systems, Man, and Cybernetics – Part C: Application and Reviews. ISBN: 38(5):609–635, 2008.

[3] Marianela Parodi. *Verificación Automática de Firmas Manuscritas.* Tesina de doctorado, Laboratorio de Sistemas Dinámicos y Procesamiento de la Información, CIFASIS, CONICET, Universidad Nacional de Rosario, Argentina, 2014.

[4] F. Nouboud S. Djeziri y R. Plamondon. *Extraction of signatures from check background based on a filiformity criterion.* IEEE Trans. Image Process. 1998. ISBN: 7(10):1425–1438.

[5] Convenio conjunto entre el gobierno de la provincia de Santa Fe y la Universidad Nacional de Rosario. *Descripción General del Proceso de Escrutinio Provisorio con Asistencia Digital.* Reporte técnico, Elecciones Provinciales, Argentina, 2019.

[6] Convenio conjunto entre el gobierno de la provincia de Santa Fe y la Universidad Nacional de Rosario. *Formato de los Códigos de Respuesta Rápida - QR.* Reporte técnico, Elecciones Provinciales, Argentina, 2019.

[7] Equipo de trabajo UNR dirigido por Dante Zanarini. *Informe sobre el Sistema de Escrutinio Provisorio con Asistencia Digital. Elecciones Generales 2019.* Reporte técnico, Universidad Nacional de Rosario, Argentina, 2019.

[8] Jianxin Wu. *Introduction to Convolutional Neural Networks.* National Key Lab for Novel Software Technology. Nanjing University, China. 2017.